

UNIVERSIDAD POLITÉCNICA DE MADRID
Escuela Técnica Superior de Ingeniería de Sistemas Informáticos



Sistema de verificación de desinformación
mediante Information Retrieval e Inferencia
del Lenguaje Natural

TRABAJO DE FIN DE MÁSTER

Presentado para la obtención del título de Máster por:

Jorge del Castillo Gómez

Madrid, 2025



UNIVERSIDAD POLITÉCNICA DE MADRID
Escuela Técnica Superior de Ingeniería de Sistemas
Informáticos



Máster en Aprendizaje Automático y Datos Masivos

Sistema de verificación de desinformación mediante Information Retrieval e Inferencia del Lenguaje Natural

TRABAJO DE FIN DE MÁSTER

Presentado para la obtención del título de Máster por:

Jorge del Castillo Gómez

Bajo la supervisión de:
Dr. Javier Huertas Tato

Madrid, 2025

Abstract

Disinformation represents a growing threat in the digital age, with direct implications for politics, public health, and social trust. This Master’s Thesis addresses this issue through the development of an automatic fact-checking system based on Information Retrieval (IR) and Natural Language Inference (NLI) techniques. The proposed system aims to assess the veracity of claims by retrieving relevant evidence from a large corpus (Wikipedia) and performing logical inference to determine whether the evidence supports, refutes, or is insufficient with respect to the claim.

The primary objective is not only to replicate existing approaches but to innovate upon the state of the art through a modular architecture that leverages advances in language models and efficient fine-tuning methods. In particular, the goal is to enhance the accuracy, scalability, and computational efficiency of current systems by integrating flexible and practical components for real-world scenarios.

The project is structured into two main phases. In the first, an inference system is implemented without active semantic retrieval, using the FEVER dataset enriched with evidence and distractors, simulating noisy information environments. In the second phase, a semantic retrieval module is introduced using the FAISS library and embeddings generated with the BGE model (BAAI/bge-small-en-v1.5), enabling efficient and context-aware vector-based search. The inference module is built upon LLaMA language models (1B, 3B, and 8B parameters), fine-tuned using Low-Rank Adaptation (LoRA), which significantly reduces computational requirements without compromising performance.

Experimental results show that LoRA substantially improves the model’s classification capabilities, eliminating the need to update all parameters of the large language model. Moreover, the integration of the semantic retrieval module significantly increases the system’s overall accuracy. Larger models (LLaMA-8B) demonstrate greater robustness, especially in scenarios involving dispersed evidence and distractors, confirming their superiority in complex fact-checking tasks.

The proposed system achieves competitive precision and recall metrics, validating its practical utility and contribution to innovation in automated disinformation detection. Finally, the thesis discusses key ethical considerations related to the use of artificial intelligence in this context, including transparency, explainability, and bias mitigation. Future research directions include the integration of generative models for automatic justification, multilingual adaptation, and deployment in real-time workflows.

Resumen

La desinformación representa una amenaza creciente en la era digital, con implicaciones directas en la política, la salud pública y la confianza social. Este Trabajo Fin de Máster aborda dicha problemática mediante el desarrollo de un sistema automático de verificación de hechos, basado en técnicas de recuperación de información (Information Retrieval, IR) e inferencia del lenguaje natural (Natural Language Inference, NLI). El sistema propuesto tiene como objetivo evaluar la veracidad de afirmaciones mediante la recuperación de evidencias relevantes desde un corpus extenso (Wikipedia) y la posterior inferencia lógica para determinar si las evidencias sustentan, refutan o resultan insuficientes respecto a la afirmación.

El objetivo principal no solo es replicar enfoques existentes, sino innovar sobre lo establecido en el estado del arte mediante una arquitectura modular que aprovecha los avances en modelos de lenguaje y técnicas de fine-tuning eficiente. En particular, se busca mejorar la precisión, escalabilidad y eficiencia de los sistemas actuales, integrando componentes que permitan una mayor flexibilidad y aplicabilidad práctica en entornos reales.

El proyecto se estructura en dos fases principales. En la primera, se implementa un sistema de inferencia sin recuperación semántica activa, utilizando el dataset FEVER enriquecido con evidencias y distractores, lo que permite simular escenarios con ruido informativo. En la segunda fase, se incorpora un módulo de recuperación semántica mediante la biblioteca FAISS y embeddings generados con el modelo BGE (BAAI/bge-small-en-v1.5), lo que habilita búsquedas vectoriales eficientes y contextuales. El módulo de inferencia se construye sobre modelos de la familia LLaMA (1B, 3B y 8B parámetros), ajustados mediante la técnica Low-Rank Adaptation (LoRA), lo cual reduce significativamente los requisitos computacionales sin comprometer el rendimiento.

Los resultados experimentales muestran que el uso de LoRA mejora sustancialmente la capacidad de clasificación del modelo, eliminando la necesidad de ajustar todos los parámetros del LLM. Asimismo, la incorporación del módulo de recuperación semántica incrementa notablemente la precisión global del sistema. Se observa que los modelos de mayor tamaño (LLaMA-8B) presentan mayor robustez, especialmente en entornos con evidencia dispersa y distractores, confirmando su superioridad en tareas complejas de verificación.

El sistema propuesto alcanza métricas competitivas en precisión y recall, validando su utilidad práctica y su contribución a la innovación en la detección automatizada de desinformación. Finalmente, el trabajo analiza consideraciones éticas clave asociadas al uso de inteligencia artificial en este contexto, como la transparencia, la explicabilidad y la mitigación de sesgos. Se plantean futuras líneas de investigación centradas en la incorporación de modelos generativos para justificar decisiones, la extensión a múltiples idiomas y la integración en flujos de trabajo en tiempo real.

Índice general

Abstract	iii
Resumen	iv
Índice de figuras	vii
Índice de tablas	ix
Abreviaturas y acrónimos	xii
1 Introduction	1
1.1 Motivación y Objetivos	2
1.2 Definición del problema	4
1.3 Organización temporal del trabajo	6
1.4 Estructura del documento	7
2 Estado del arte	9
2.1 Background	9
2.1.1 Técnicas de similitud semántica	9
2.2 Sistemas Tradicionales de Fact-Checking	10
2.2.1 FacTer-Check: Un Enfoque Avanzado para Fact-Checking	11
2.2.2 Eficacia de los Modelos Transformers Ajustados Frente a los Modelos de Lenguaje Grande (LLMs) en Tareas de Verificación de Hechos	13
2.3 Técnicas de Fine-Tuning de Modelos Grandes de Lenguaje (LLM)	14
2.3.1 Low-Rank Adaptation (LoRA)	14
3 Entorno hardware y software, Conjunto de Datos	17
3.1 <i>Hardware</i>	17
3.2 <i>Software</i>	18
3.3 Conjunto de Datos. Dataset FEVER	19
Descripción del dataset	19
4 Implementación y desarrollo	23
4.1 Preprocesado. Codificación de Embeddings	23
4.2 Arquitectura	24
4.2.1 Módulo 1. Information Retrieval	24
Primera aproximación: recuperación basada en FEVER	25
Segunda aproximación: Recuperación semántica (SIR) con FAISS	26
4.2.2 Modulo 2. Inferencia del Lenguaje Natural (NLI)	27

4.2.3	Interacción entre módulos	30
4.3	Entrenamiento y configuración de hiperparámetros	31
4.3.1	Particionamiento de datos	32
4.3.2	Métricas de evaluación	33
4.3.3	Experimentos y comparaciones	33
5	Resultados	35
5.1	Resultados 1º Fase: Evaluación del módulo de inferencia con y sin LoRA (sin recuperación semántica)	35
5.1.1	Evaluación sin LoRA	35
	Llama-3.2-1B	36
	Llama-3.2-3B	37
	Comparativa general entre modelos sin LoRA	37
5.1.2	Evaluación con LoRA	38
	Llama-3.2-1B + LoRA	38
	Llama-3.2-3B + LoRA	39
	Llama-3.1-8B + LoRA	40
	Comparativa general de los modelos con LoRA	41
5.2	Resultados 2º Fase: Evaluación del impacto del Módulo de IR sobre el Módulo de Inferencia	42
5.2.1	Evaluación del módulo SIR de forma desacoplada	42
5.2.2	Evaluación conjunta: SIR + NLI	42
	Llama-3.2-1B + LoRA + SIR	42
	Llama-3.2-3B + LoRA + SIR	43
	Llama-3.1-8B + LoRA + SIR	44
5.2.3	Comparativa general de los modelos con LoRA + SIR	45
6	Discusión	47
6.1	1º Fase. Evaluación del módulo de inferencia con y sin ajuste fino (sin recuperación semántica)	47
6.2	2º Fase. Evaluación del impacto del Módulo de IR sobre el Módulo de Inferencia	48
6.3	Comparación con el estado del arte	49
7	Aspectos Éticos	51
7.1	Consideraciones Éticas	51
7.2	Impactos Éticos	51
7.3	Ethics by Design en el Desarrollo	52
7.3.1	Especificación de objetivos	52
7.3.2	Especificación de requisitos	53
7.3.3	Diseño de alto nivel	53
7.3.4	Recopilación y preparación de los datos	54
7.3.5	Diseño detallado y desarrollo	54
7.3.6	Pruebas y validación	54
7.3.7	Conclusiones Éticas	55

8	Conclusiones y trabajos futuros	57
8.1	Conclusiones	57
8.1.1	Conclusiones relacionadas con el proyecto	57
8.2	Trabajos futuros	58
8.2.1	Conclusiones personales	58

Índice de figuras

1.1	Top riesgos globales susceptibles de ser resueltos por la educación pública. Fuente: [19]	2
1.2	Arquitectura inicial del sistema automático de verificación de afirmaciones basado en Information Retrieval (IR) y Natural Language Inference (NLI). .	4
1.3	Planificación temporal del proyecto por fases	6
2.1	<i>Pipeline</i> propuesto para la generación de embeddings a nivel de documento. Fuente: [6]	10
2.2	Diagrama arquitectónico de los 3 componentes de FacTeR-Check. Fuente: [6]	11
2.3	Sistema arquitectónico del pipeline <i>fact-checking</i> . Fuente: [12]	13
2.4	Esquema de <i>Low Rank Adaptation</i> (LoRA) <i>fact-checking</i> . Fuente: [5]	15
3.1	Visualización del conjunto de entrenamiento respecto la media de <i>tokens</i> por cla- se, distribución verificable por clase, media de evidencias por clase y distribución de etiquetas	20
3.2	Visualización del conjunto de validación respecto la media de <i>tokens</i> por clase, distribución verificable por clase, media de evidencias por clase y distribución de etiquetas	21
4.1	Arquitectura del sistema de verificación de desinformación usando IR y NLI con adaptación LoRA y recuperación de información	24
4.2	Sistema de recuperación de información con FAISS	27
4.3	Arquitectura del módulo NLI	28
5.1	Matriz de confusión del mejor modelo sin LoRA (Llama-3.2-1B)	36
5.2	Matriz de confusión del mejor modelo sin LoRA (Llama-3.2-3B)	37
5.3	Matriz de confusión del modelo Llama-3.2-1B con LoRA	39
5.4	Matriz de confusión del modelo Llama-3.2-3B con LoRA	40
5.5	Matriz de confusión del modelo Llama-2-7B con LoRA	41
5.6	Matriz de confusión del modelo Llama-3.2-1B con LoRA + SIR	43
5.7	Matriz de confusión del modelo Llama-3.2-3B con LoRA + SIR	44
5.8	Matriz de confusión del modelo Llama-2-7B con LoRA + SIR	44

Índice de tablas

4.1	Comparativa de almacenamiento entre modelos LLaMA y versiones cuantizadas de Unsloth	29
4.2	Hiperparámetros de entrenamiento sin LoRA	31
4.3	Hiperparámetros de entrenamiento con LoRA	31
4.4	Distribución del dataset por partición (primera aproximación sin módulo SIR)	32
4.6	Características del conjunto de prueba (segunda aproximación con módulo SIR)	32
4.8	Resumen de los experimentos realizados. Las filas coloreadas agrupan los modelos que se comparan directamente. En la Fase 1 se estudia el impacto de LoRA sin recuperación semántica. En la Fase 2 se evalúa el efecto de incorporar recuperación semántica sobre modelos ajustados con LoRA.	34
5.1	Resultados de las ejecuciones con Llama-3.2-1B-bnb-4bit sin LoRA	36
5.2	Resultados de las ejecuciones con Llama-3.2-3B-bnb-4bit sin LoRA	37
5.3	Comparación entre modelos sin LoRA: métricas promedio (μ) y desviación estándar (σ)	37
5.4	Resultados del modelo Llama-3.2-1B-bnb-4bit con LoRA	38
5.5	Resultados del modelo Llama-3.2-3B-bnb-4bit con LoRA	39
5.6	Resultados del modelo Llama-3.1-8B-bnb-4bit con LoRA	40
5.7	Comparación entre modelos con LoRA	41
5.8	Resultados del modelo Llama-3.2-1B-bnb-4bit con LoRA y SIR	43
5.9	Resultados del modelo Llama-3.2-3B-bnb-4bit con LoRA y SIR	43
5.10	Resultados del modelo Llama-3.1-8B-bnb-4bit con LoRA y SIR	45
5.11	Comparación entre modelos con LoRA y SIR	45
6.1	Comparación de modelos con y sin LoRA: métricas promedio (μ), desviación estándar (σ) y tiempo de entrenamiento en minutos.	47
6.2	Comparación entre modelos con LoRA sin IR y con IR: métricas y diferencias.	48
6.3	Comparación de modelos ordenados por Accuracy. Los modelos en gris son nuestras variantes LLaMA con LoRA y recuperación semántica (IR).	49

Abreviaturas y acrónimos

UPM Universidad Politécnica de Madrid

IR Information Retrieval (Recuperación de Información)

NLI Natural Language Inference (Inferencia del Lenguaje Natural)

LLM Large Language Model (Modelo de Lenguaje de Gran Escala)

LoRA Low-Rank Adaptation (Adaptación de Bajo Rango)

SIR Semantic Information Retrieval (Recuperación Semántica de Información)

FEVER Fact Extraction and VERification (Extracción y Verificación de Hechos)

BGE BAAI General Embeddings (Embeddings Generales del BAAI)

PLN Procesamiento del Lenguaje Natural

MTEB Massive Text Embedding Benchmark

AI Artificial Intelligence (Inteligencia Artificial)

NLP Natural Language Processing (Procesamiento de Lenguaje Natural)

FAISS Facebook AI Similarity Search

Capítulo 1

Introduction

La desinformación ha sido una constante en la sociedad humana, utilizada como herramienta de manipulación y control en diferentes contextos históricos, según [7]. Aunque en la actualidad la difusión masiva y rápida de noticias falsas parece un fenómeno reciente, en realidad, el periodismo y la comunicación han convivido desde sus inicios con la tergiversación intencionada de la verdad, la manipulación de la información y la pérdida de credibilidad de los medios. Lejos de ser una anomalía moderna, la desinformación ha formado parte de las estrategias ideológicas y comerciales a lo largo del tiempo, transformando la realidad y afectando la confianza en las instituciones.

La propagación de información falsa ha adquirido una dimensión crítica en la era digital, donde la facilidad para publicar contenido en la web ha incrementado la difusión de *fakes news* sin mecanismos de verificación efectivos [3]. Este problema se ha visto amplificado con la llegada del Web 2.0, permitiendo que noticias falsas y desinformación se expandan rápidamente a través de plataformas digitales. La capacidad de esta desinformación para mimetizarse con información legítima las convierte en un desafío significativo para la sociedad, afectando la toma de decisiones en ámbitos como la política, la salud y la economía.

Un ejemplo claro del impacto que puede tener la desinformación es en la reciente pandemia SARS-CoV-2. Los medios de comunicación y usuarios de las redes sociales perpetuaron rumores para no vacunarse, promovieron el uso de medicamentos no recomendados y fomentaron teorías conspirativas sin respaldo en datos oficiales [1]. La autorización del uso de vacunas reavivó la desconfianza general de la sociedad en la ciencia; junto con la rápida difusión de información falsa, convirtió la resistencia a la vacunación en una pandemia paralela. Luego, es importante contar con fuentes de información creíbles y una monitorización continua de las plataformas de redes sociales para garantizar que se transmita información precisa al público.

La desinformación también tiene implicaciones de gran alcance para los derechos humanos y las normas democráticas a nivel global. Amenaza la libertad de pensamiento, el derecho a la privacidad y el derecho a la participación democrática. En [2], proponen la necesidad de implementar respuestas efectivas contra la desinformación por parte de la Unión Europea (UE), evitando la degeneración de los derechos humanos.

El World Economic Forum publicó un informe sobre los mayores riesgos globales para 2024




Figura 1.1: Top riesgos globales susceptibles de ser resueltos por la educación pública. Fuente: [19]

[19]. En la Figura 1.1 se presenta la lista de riesgos más susceptibles de ser abordados desde la concienciación y la educación pública. En primer lugar, se encuentra la desinformación, destacando la importancia de fomentar la conciencia pública y la educación, preparando a las personas para identificar y abordar la desinformación de manera efectiva.

1.1 Motivación y Objetivos

Han surgido múltiples iniciativas para combatir la desinformación, desde verificadores manuales operados por periodistas y organizaciones especializadas hasta sistemas automatizados que buscan optimizar este proceso. Sin embargo, los enfoques manuales son lentos y costosos, lo que hace inviable su aplicación a gran escala en un entorno donde el volumen de datos crece exponencialmente.

Diversos estudios han demostrado que los verificadores humanos pueden tardar desde varias horas hasta días en desmentir una sola afirmación, mientras que la desinformación se difunde de forma mucho más veloz. De hecho, se ha documentado que los bulos y contenidos falsos se propagan hasta seis veces más rápido que sus respectivas correcciones [18]. Este desfase temporal compromete la eficacia del fact-checking manual, haciéndolo insuficiente para responder a las exigencias del ecosistema digital actual.

Por ello, los sistemas automáticos de verificación se han convertido en una alternativa clave, combinando técnicas de *Information Retrieval* (IR) e *Inferencia del Lenguaje Natural* (NLI) para evaluar la veracidad de una afirmación en función de fuentes confiables. Un ejemplo relevante es la herramienta *ClaimHunter*, desarrollada por Newtral, que ha demostrado reducir hasta en un 70–80 % el tiempo necesario para identificar afirmaciones susceptibles de verificación, facilitando el trabajo de los verificadores humanos [11].

En el estado del arte, se ha demostrado que los modelos basados en IR y NLI son fundamentales

para el desarrollo de sistemas de verificación eficientes. Mientras que *Information Retrieval* permite recuperar evidencias relevantes desde grandes repositorios de datos, *Natural Language Inference* es capaz de determinar la relación entre una afirmación y las evidencias encontradas, estableciendo si la afirmación es verdadera, falsa o indefinida. Estos métodos han sido utilizados en proyectos como el sistema de fact-checking de Google, Fact Extraction and VERification (FEVER), así como en modelos basados en transformers como BERT y RoBERTa, mostrando resultados prometedores en la detección automatizada de desinformación.

Objetivos

Bajo las circunstancias descritas, el presente Trabajo Fin de Máster (TFM) adquiere especial relevancia. Su objetivo principal es desarrollar un sistema automático de verificación de desinformación mediante técnicas de *Deep Learning*, incorporando un módulo de *Information Retrieval* e *Inferencia del Lenguaje Natural*. Este sistema busca combinar técnicas avanzadas de recuperación de información y modelos de inferencia semántica para proporcionar una verificación automática y fundamentada de afirmaciones, contribuyendo así a mitigar el impacto de la desinformación en la sociedad.

Para llevar a cabo este trabajo experimental, se han definido una serie de objetivos específicos con el propósito de alcanzarlos:

- Estudiar el fenómeno de la desinformación, analizando su impacto en distintos ámbitos como la política, la salud pública y la sociedad en general.
- Explorar técnicas de *Information Retrieval*, comprendiendo su papel en la recuperación eficiente de información relevante para la verificación de afirmaciones.
- Investigar sobre *Natural Language Inference* (NLI), con el objetivo de entender cómo los modelos pueden evaluar la relación entre afirmaciones y evidencias para determinar su veracidad.
- Revisar trabajos previos en verificación automática de hechos, analizando métodos tradicionales y enfoques modernos basados en inteligencia artificial.
- Investigar y seleccionar un conjunto de datos de acceso público adecuado para entrenar el modelo de verificación de desinformación.
- Diseñar e implementar un sistema automático de verificación de desinformación, integrando módulos de *Information Retrieval* e inferencia del lenguaje natural.
- Definir métricas de evaluación para medir el desempeño del sistema en la verificación automática de afirmaciones.

Este proyecto tiene como objetivo desarrollar un sistema de verificación automática de hechos basado en modelos de lenguaje ¹.

¹El código fuente completo se encuentra disponible en: <https://github.com/JorgeDC01/Misinformation-verification-NLI-IR>

1.2 Definición del problema

El presente trabajo aborda el problema de la verificación automática de afirmaciones potencialmente falsas que circulan en entornos reales, con el objetivo de reducir el impacto de la desinformación. La problemática se enmarca en un contexto donde el volumen de contenido generado y compartido diariamente en redes sociales y medios digitales hace inviable una verificación manual por parte de expertos humanos.

El problema puede formularse como una tarea de clasificación basada en evidencias: dado un conjunto de afirmaciones y una base de conocimiento (corpus de documentos confiables), se busca determinar automáticamente si la afirmación es verdadera, falsa o no verificable. Para ello, se propone un sistema preliminar compuesto por dos módulos principales (véase la Figura 1.2):

- **Information Retrieval (IR):** encargado de recuperar, desde una base de datos, documentos relevantes que puedan contener evidencia a favor o en contra de la afirmación analizada.
- **Natural Language Inference (NLI):** responsable de inferir, a partir del texto recuperado, si la información respalda, contradice o es neutral respecto a la afirmación original.

El flujo del sistema se puede esquematizar de la siguiente forma:




Figura 1.2: Arquitectura inicial del sistema automático de verificación de afirmaciones basado en Information Retrieval (IR) y Natural Language Inference (NLI).

Entrada: afirmación en lenguaje natural (por ejemplo: “La vacuna contra la COVID-19 altera el ADN”).

Salida: es una etiqueta que indica si la afirmación está *respaldada*, *contradicha* o es *no*

verifiable según las evidencias recuperadas.

Este enfoque busca combinar el poder de recuperación semántica del IR con las capacidades inferenciales de modelos de lenguaje entrenados para NLI. Más adelante, en el Capítulo 4, se detalla la implementación y el desarrollo del sistema.

1.3 Organización temporal del trabajo




Figura 1.3: Planificación temporal del proyecto por fases

Para la consecución de los objetivos se ha seguido la planificación temporal ilustrada en la Figura 1.3. En la imagen, la planificación se divide en 4 fases diferenciadas, que se desglosan entre los meses de enero y junio:

- **Estado del Arte:** En esta fase se abarcan las tareas de formación y aprendizaje autónomo, investigación y lecturas para adquirir el conocimiento necesario para desarrollar el proyecto.
- **Preprocesado de los datos:** Previo a la fase de implementación, es crucial analizar los datos que se van a manejar, cómo están representados y procesarlos en un formato legible para las redes neuronales.
- **Implementación:** Esta fase se centra en la implementación del sistema de verificación de desinformación.
- **Memoria:** La fase final consiste en la redacción de la memoria del proyecto, una vez que el problema está definido y se ha adquirido el contexto suficiente.

1.4 Estructura del documento

En el presente apartado, se le proporciona al lector la estructura que se sigue del resto del documento para facilitarle la comprensión del mismo. Las secciones restantes son:

- **Capítulo 2: Estado del arte** - Se presenta un análisis de los enfoques actuales en verificación de desinformación, con énfasis en el uso de técnicas de *Information Retrieval* e inferencia del lenguaje natural.
- **Capítulo 3: Entorno hardware y software, Conjunto de Datos** - Se describen las herramientas y tecnologías utilizadas en el desarrollo del proyecto, incluyendo el hardware empleado y los entornos de software seleccionados, así como un análisis exploratorio del dataset utilizado en el trabajo.
- **Capítulo 4: Implementación y desarrollo** - Se detalla el proceso de desarrollo del sistema propuesto, explicando las metodologías empleadas y los desafíos encontrados.
- **Capítulo 5: Resultados** - Se presentan los resultados intermedios obtenidos durante el desarrollo del sistema, incluyendo las métricas clave de evaluación para las primeras fases experimentales.
- **Capítulo 6: Discusión** - Se analizan en detalle los resultados de las fases finales del sistema, profundizando en su interpretación y sus implicaciones prácticas.
- **Capítulo 7: Aspectos Éticos** - Se abordan las implicaciones éticas del sistema propuesto, incluyendo aspectos relacionados con la privacidad, los sesgos algorítmicos y el uso responsable de modelos de lenguaje.
- **Capítulo 8: Conclusiones** - Se resumen los hallazgos del trabajo, las contribuciones principales y posibles líneas de investigación futuras.

Capítulo 2

Estado del arte

En este capítulo se realiza una revisión sistemática del estado del arte en relación con las técnicas de similitud semántica entre textos, e inferencia del lenguaje natural aplicadas a la verificación de desinformación. Finalmente, se expone la línea de investigación principal que sirve como punto de partida para el presente trabajo.

2.1 Background

2.1.1 Técnicas de similitud semántica

La medición de la similitud semántica entre pares de textos ha sido un problema abordado desde las áreas de procesamiento de lenguaje natural (PLN) y recuperación de información (IR). Esta tarea es clave para numerosos sistemas de IR, ya que permite identificar la relación semántica entre una consulta y documentos candidatos, o en el contexto del presente trabajo, entre afirmaciones (claims) y textos verificados.

Las primeras aproximaciones se basaron en métodos léxicos, los cuales calculan la similitud en función de la coincidencia exacta entre palabras o secuencias de caracteres (n-gramas), como describen [4]. Estos métodos, también conocidos como string-based, presentan grandes limitaciones al no considerar la semántica subyacente ni detectar sinónimos o relaciones semánticas entre conceptos.

Para superar estas limitaciones, surgieron métodos basados en corpus, los cuales utilizan grandes conjuntos de datos textuales para construir espacios vectoriales, utilizando técnicas como la creación de representaciones distribuidas de términos mediante modelos como *Word2Vec* de [8].

La introducción de arquitecturas basadas en atención, como Transformer [17] que permiten generar representaciones contextuales (embeddings) ricas en información semántica, ha supuesto un gran avance en la tarea de similitud semántica. Estas representaciones vectoriales permiten ubicar frases o textos completos en un espacio multidimensional, donde la distancia refleja la cercanía semántica entre ellos.

La medición de la similitud semántica mediante modelos como Transformers o Word2Vec incorpora el concepto de embedding, entendido como una representación numérica del contenido textual. La granularidad de estas representaciones puede variar, existiendo embeddings a nivel de token, frase o documento completo.

En el contexto de la detección automática de desinformación, una de las decisiones clave radica en el nivel de granularidad con el que se representa el texto. Dos enfoques predominantes son el uso de embeddings a nivel de documento y a nivel de frase, cada uno con ventajas y limitaciones.

Los embeddings a nivel de documento tienen como objetivo capturar una representación global del texto completo. Esta estrategia ha demostrado ser eficaz en contextos donde la información relevante se distribuye a lo largo del contenido. En este sentido, el estudio de [15] destaca que las representaciones documentales generadas mediante modelos basados en transformadores, como BART, alcanzan un rendimiento notablemente superior en la clasificación de noticias falsas, incluso frente a arquitecturas más complejas. En la Figura 2.1 se observa el *pipeline* implementado para la detección de *fake news*. Su investigación concluye que, para detectar patrones semánticos amplios y señales sutiles de manipulación, los embeddings a nivel de documento son una alternativa robusta.




Figura 2.1: *Pipeline* propuesto para la generación de embeddings a nivel de documento. Fuente: [6]

Por otro lado, los embeddings a nivel de frase han sido explorados como una alternativa más granular, centrada en la estructura interna del texto. El trabajo de [16] propone un enfoque basado en redes neuronales gráficas que modelan las interacciones entre oraciones, bajo la premisa de que la desinformación no siempre es evidente a nivel global, sino que puede manifestarse en frases concretas del texto. Este tipo de representación permite detectar contradicciones o afirmaciones engañosas localizadas, proporcionando una perspectiva más detallada que la visión global del documento.

Recapitulando, mientras los embeddings a nivel de documento favorecen una comprensión holística del contenido, los embeddings a nivel de frase permiten un análisis más fino y focalizado. La elección entre ambos enfoques dependerá de las características específicas del contenido a analizar y de los objetivos de la arquitectura de verificación empleada.

2.2 Sistemas Tradicionales de Fact-Checking

Los métodos tradicionales de verificación automática de hechos se basan en clasificadores de aprendizaje automático que utilizan una base de conocimientos inicial e inmutable [6]. Sin

embargo, estos enfoques tienen dificultades en escenarios de *zero-shot prediction*, donde se enfrentan a afirmaciones no previamente verificadas. Para abordar esta limitación, *FacTer-Check* introduce el uso de fuentes de información actualizadas y modelos avanzados de NLP.

2.2.1 FacTer-Check: Un Enfoque Avanzado para Fact-Checking

El sistema **FacTer-Check** está compuesto por dos módulos principales: el módulo de similitud semántica y el módulo de inferencia de lenguaje natural (NLI).

En la Figura 2.2 se visualiza la arquitectura empleada en [6], formada por 3 componentes.




Figura 2.2: Diagrama arquitectónico de los 3 componentes de FacTer-Check. Fuente: [6]

El **módulo de Similitud Semántica** busca en bases de datos actualizadas afirmaciones verificadas similares a la afirmación de entrada (input claim). Para ello, emplea un ensemble de modelos *Transformers* que generan representaciones vectoriales (embeddings) y calculan la distancia coseno para determinar similitudes.

Los modelos utilizados en el ensemble incluyen:

- *paraphrase-xlm-r-multilingual-v1*: basado en RoBERTa, optimizado para detección de parafrasis.
- *stsb-xlm-r-multilingual*: entrenado en inferencia de lenguaje natural (NLI) y el benchmark STS.

- *paraphrase-multilingual-MiniLM-L12-v2*: modelo ligero de Microsoft optimizado para parafrásis.
- *paraphrase-multilingual-mpnet-base-v2*: versión de MPNet optimizada para tareas multilingües.

Este módulo tiene dos objetivos principales: Cuando encuentra hoaxes semánticamente similares en la base de datos, el sistema puede informar al usuario sobre afirmaciones relacionadas que ya han sido verificadas, proporcionando contexto y antecedentes. También actúa como un filtro para seleccionar las afirmaciones verificadas que serán enviadas al módulo de Inferencia de Lenguaje Natural (NLI).

Dado que el cálculo de la distancia coseno entre embeddings es computacionalmente costoso, se implementa *Principal Component Analysis* (PCA) para reducir la dimensionalidad de los embeddings, eliminando redundancia sin perder información relevante.

El siguiente **módulo de Inferencia de Lenguaje Natural** (NLI) analiza si una afirmación de entrada está alineada con una afirmación previamente verificada y determina la relación entre ambas:

- *Entailment*: la afirmación de entrada se deriva lógicamente de una afirmación verificada.
- *Contradiction*: la afirmación de entrada contradice una afirmación verificada.
- *Neutral*: no hay relación clara entre ambas afirmaciones.

El *claim input* y las evidencias seleccionadas son procesadas por el módulo de Inferencia de Lenguaje Natural (NLI). Este módulo evalúa si existe *entailment* (coincidencia lógica) entre el *claim input* y cada una de las evidencias.

Si se detecta *entailment* con alguna evidencia, el sistema puede determinar si la afirmación de entrada es falsa (si la evidencia corresponde a un hoax) o verdadera (si la evidencia ha sido verificada como auténtica).

Si no se encuentra *entailment*, significa que el *claim input* no se alinea directamente con las evidencias recuperadas. Esto puede indicar que la afirmación no es semánticamente compatible con los *claims* existentes, o bien que es demasiado ambigua o novedosa para ser verificada con la información disponible.

Para la tarea del artículo, se emplea el modelo *XLM-RoBERTa-large*, ajustado mediante *fine-tuning* en datasets como MNLI-MT, XNLI y FEVER. Este ajuste permite que el sistema maneje mejor afirmaciones en diversos idiomas y dominios.

El enfoque propuesto en este trabajo guarda una estrecha relación con el sistema FacTer-Check, que también integra un módulo de recuperación de información (IR) y un módulo de inferencia de lenguaje natural (NLI). En FacTer-Check, el módulo de IR se encarga de recuperar afirmaciones verificadas similares a la afirmación de entrada, mientras que el módulo de NLI evalúa la relación semántica entre las afirmaciones y las evidencias recuperadas. En este sentido, mi investigación sigue una estructura similar, combinando un sistema de IR con un módulo de inferencia de lenguaje, pero con un enfoque adicional.

2.2.2 Eficacia de los Modelos Transformers Ajustados Frente a los Modelos de Lenguaje Grande (LLMs) en Tareas de Verificación de Hechos

En el trabajo de Setty [12], se propone un pipeline de verificación de hechos centrado en tres etapas principales: la detección de afirmaciones relevantes, la búsqueda de evidencia y la predicción de veracidad (véase la Figura 2.3). Este sistema utiliza modelos Transformer, específicamente el modelo XLM-RoBERTa-Large, para las tareas de clasificación de afirmaciones relevantes para la verificación. En la segunda etapa, se recuperan fragmentos de evidencia relacionados con las afirmaciones utilizando técnicas de recuperación de información (IR). Finalmente, en la etapa de verificación, el modelo XLM-RoBERTa-Large predice la veracidad de las afirmaciones mediante un proceso de inferencia de lenguaje natural (NLI), determinando si la evidencia respalda o refuta la afirmación. Además, en este enfoque, las evidencias se agrupan utilizando votación mayoritaria, y se utilizan LLMs para generar justificaciones y correcciones para las afirmaciones refutadas.

En su trabajo, concluyen que los modelos Transformers responden mejor en tareas relacionadas con verificación de hechos; sin embargo, concluyen que los LLM son mejores en la justificación.




Figura 2.3: Sistema arquitectónico del pipeline *fact-checking*. Fuente: [12]

El trabajo presentado en este TFM también parte del enfoque de Setty, particularmente en los módulos de *information retrieval* e *natural language inference* (NLI). Al igual que Setty, la arquitectura propuesta utiliza un módulo de IR para recuperar evidencia relevante y un módulo de NLI para evaluar la relación entre las afirmaciones y las evidencias. Sin embargo, a diferencia de su estrategia, que aplica modelos Transformer fine-tuned como XLM-RoBERTa-Large para evaluar de forma individual cada fragmento de evidencia, el enfoque aquí propuesto utiliza un modelo de lenguaje de gran tamaño (LLM) al que se le proporciona toda la información de contexto (afirmación, evidencias y distractores) de manera conjunta.

Aunque en este trabajo no se emplea el LLM para tareas de generación de texto, sino exclusivamente como clasificador, su integración en la arquitectura presenta dos ventajas clave:

- Los LLM permiten manejar ventanas de contexto considerablemente más amplias, lo cual resulta especialmente útil cuando se dispone de múltiples fragmentos de evidencia dispersa. Esta capacidad posibilita una evaluación más completa del conjunto de información relevante.

- Estos modelos también facilitan la explicabilidad del proceso de verificación, al permitir generar razonamientos o justificaciones sobre por qué una afirmación es considerada verdadera o falsa en función de las evidencias. Este aspecto es destacado también por Setty [12], quien señala la superioridad de los LLM en tareas generativas como la generación de justificaciones o correcciones.

En resumen, aunque los modelos Transformer especializados, como XLM-RoBERTa-Large, han demostrado un rendimiento superior en tareas de verificación de desinformación (según los resultados descritos por Setty [12]), el uso de LLMs en este trabajo se justifica por su capacidad para integrar un mayor contexto y ofrecer una vía más flexible y explicativa para abordar la tarea de veracidad desde una perspectiva global.

A diferencia del enfoque propuesto por Setty, que evalúa individualmente cada fragmento de evidencia para determinar su postura respecto a una afirmación, en mi propuesta tanto las evidencias como las afirmaciones se presentan de forma conjunta al modelo LLM como un único contexto. Esto permite que el modelo realice una clasificación holística sobre la veracidad de la afirmación.

Además, esta integración se ve reforzada mediante una proyección previa de los *embeddings* contextuales, que permiten representar de forma compacta el conjunto de evidencias.

2.3 Técnicas de Fine-Tuning de Modelos Grandes de Lenguaje (LLM)

2.3.1 Low-Rank Adaptation (LoRA)

Uno de los principales desafíos del fine-tuning de modelos de lenguaje de gran escala (LLMs) es el alto coste computacional y de memoria asociado a la actualización de todos sus parámetros. *Low-Rank Adaptation* (LoRA) [5] surge como una solución eficiente a este problema mediante la adaptación de un subconjunto reducido de parámetros entrenables, preservando los parámetros originales del modelo congelados.

LoRA se basa en la hipótesis de que las actualizaciones de los pesos durante el proceso de fine-tuning poseen un *rango intrínseco* bajo. En lugar de modificar directamente la matriz de pesos W_0 de una capa densa, se introduce una actualización parametrizada como una descomposición de rango bajo: $\Delta W = BA$, donde $A \in \mathbb{R}^{r \times d}$ y $B \in \mathbb{R}^{k \times r}$, siendo $r \ll \min(k, d)$. Así, los pesos efectivos del modelo durante el entrenamiento son $W' = W_0 + \Delta W$, manteniéndose W_0 congelados y entrenando únicamente las matrices A y B . La Figura 2.4, extraída del artículo original de LoRA [5], muestra de forma esquemática el funcionamiento del método. En ella se observa cómo las matrices de pesos de las capas densas del modelo se mantienen congeladas, y se introducen matrices de bajo rango (A y B) que permiten adaptar el modelo a nuevas tareas con un coste computacional reducido.




Figura 2.4: Esquema de *Low Rank Adaptation (LoRA) fact-checking* . Fuente: [5]

Las ventajas de LoRA son múltiples:

- Reduce significativamente el uso de memoria y los requerimientos computacionales durante el entrenamiento, permitiendo adaptaciones eficientes en GPUs con recursos limitados.
- Permite compartir el modelo base para múltiples tareas, almacenando únicamente las matrices de adaptación, lo que facilita el *fine-tuning* multi-tarea y reduce el coste de almacenamiento.
- No introduce latencia adicional en la inferencia, ya que la suma de $W_0 + \Delta W$ puede realizarse de forma eficiente.
- LoRA ha demostrado rendimientos comparables, e incluso superiores, al ajuste fino completo en tareas como clasificación, generación de texto y NL2SQL.

Dado su enfoque eficiente, LoRA representa una estrategia particularmente útil en escenarios donde los recursos computacionales son limitados o cuando se requiere un cambio rápido entre tareas específicas dentro de un mismo modelo base.

El uso de modelos de lenguaje de gran escala (LLMs), como Llama 2, ha abierto nuevas posibilidades en la detección y análisis automatizado de desinformación y narrativas propagandísticas. Sin embargo, el proceso de *fine-tuning* completo de estos modelos implica un costo computacional elevado, lo que lo hace poco viable en contextos con recursos limitados.

En el trabajo de [10], se demuestra que mediante el uso de LoRA es posible afinar un modelo Llama 2 de 7B parámetros para tareas específicas como la detección de desinformación, el resumen automático, el análisis de entidades nombradas y la clasificación de sentimientos.

Los resultados obtenidos en su investigación muestran que, aunque la calidad del análisis depende en gran medida del conjunto de datos y las instrucciones de entrenamiento, el modelo ajustado con LoRA es capaz de generar respuestas estructuradas útiles para el análisis de noticias.

Capítulo 3

Entorno hardware y software, Conjunto de Datos

En este capítulo se describe el entorno de trabajo en el que se desarrolla el presente proyecto. Se exponen las especificaciones hardware y el software empleadas en el Capítulo 4. Implementación y desarrollo

3.1 *Hardware*

En una primera fase experimental del trabajo, se optó por el entorno de trabajo de Google: *Google Colaboratory*¹. Se prefirió la infraestructura de *Google Colaboratory* debido a la disponibilidad de la *GPU T4*, la cual facilita el cálculo de las operaciones matriciales con transformers. Es importante destacar que, aunque *Google Colaboratory* ofrece recursos adicionales, también tiene sus propias limitaciones de tiempo de uso.

En la etapa de la implementación de modelos, el entorno de Google Colab se sustituyó por un entorno de trabajo proporcionado por la Universidad. En ese entorno, se utilizaron diferentes GPUs según la disponibilidad del momento.

A continuación se presenta una lista descriptiva de las tarjetas gráficas instaladas en el sistema:

- **GPU 0:** NVIDIA A40 - Tarjeta gráfica de alto rendimiento diseñada para cargas de trabajo intensivas en IA y renderizado. Capacidad máxima: 46 GB de memoria.
- **GPU 1:** NVIDIA GeForce RTX 3090 - Potente GPU orientada a gaming y creación de contenido, con gran capacidad de memoria. Capacidad máxima: 24 GB de memoria.
- **GPU 2:** NVIDIA GeForce RTX 3090 - Mismo modelo que la anterior, ideal para procesamiento paralelo y cargas pesadas. Capacidad máxima: 24 GB de memoria.
- **GPU 3:** NVIDIA GeForce RTX 3090 - Otra unidad del mismo modelo, optimizada para tareas intensivas en gráficos y cómputo. Capacidad máxima: 24 GB de memoria.

¹ ***Google Colaboratory***: es un servicio de Google alojado de *Jupyter Notebook* que no requiere configuración y permite ejecutar código *Python*, adecuado para aprendizaje automático y ciencia de datos.

- **GPU 4:** NVIDIA RTX 4500 Ada Generation - Nueva generación de tarjetas para visualización avanzada y computación acelerada. Capacidad máxima: 24 GB de memoria.
- **GPU 5:** NVIDIA RTX 4500 Ada Generation - Segunda unidad del mismo modelo, diseñada para rendimiento extremo en aplicaciones profesionales. Capacidad máxima: 24 GB de memoria.

3.2 Software

Se trabaja con el lenguaje de programación de **Python**². Se selecciona este lenguaje porque incluye las librerías más populares en el manejo de transformers: **PyTorch**, **HuggingFace** y **Transformers**.

A continuación, se listan las librerías de *Python* más destacables que se han empleado:

- **Pandas**³: biblioteca de software de código abierto que recoge las funciones esenciales para la manipulación y análisis de datos en *Python*. Esta biblioteca fue creada como una herramienta de alto nivel para el análisis y manipulación de datos. Es una de las bibliotecas más populares en *Ciencia de Datos*.
- **Matplotlib**⁴: biblioteca de visualización de gráficos de bajo nivel en *Python*. Permite visualizar datos almacenados en objetos *arrays* de la librería *Numpy* y proporciona muchas funciones para personalizar la apariencia de los gráficos.
- **PyTorch**⁵: biblioteca de código abierto para aprendizaje automático y redes neuronales profundas. Es conocida por su flexibilidad, eficiencia y facilidad de uso, especialmente en investigaciones científicas. Proporciona soporte completo para modelos de aprendizaje profundo y computación en GPUs.
- **Hugging Face**⁶: plataforma de código abierto que facilita la creación, el entrenamiento y la implementación de modelos de procesamiento de lenguaje natural (NLP). Proporciona una amplia gama de modelos preentrenados y herramientas para facilitar el uso de modelos avanzados de aprendizaje profundo.
- **Datasets**⁷: biblioteca de *Hugging Face* para cargar y compartir conjuntos de datos de manera sencilla. Facilita el preprocesamiento de datos para tareas de *NLP* y otras áreas, permitiendo manejar datos de manera eficiente en proyectos de *Machine Learning*.

² **Python**: es un lenguaje de programación de alto nivel, orientado a objetos que se moldea bien para tareas de ciencia de datos: preprocesado de datos, visualización, aprendizaje automático, profundo, etc

³ **Pandas**: Página Oficial: <https://pandas.pydata.org>

⁴ **Matplotlib**: Página Oficial: <https://matplotlib.org>

⁵ **PyTorch**: Página Oficial: <https://pytorch.org>

⁶ **Hugging Face**: Página Oficial: <https://huggingface.co>

⁷ **Datasets**: Página Oficial: <https://huggingface.co/datasets>

3.3 Conjunto de Datos. Dataset FEVER

El dataset FEVER (*Fact Extraction and Verification*) es un conjunto de datos diseñado específicamente para la verificación de hechos en el ámbito del procesamiento del lenguaje natural (NLP). Es ampliamente utilizado en investigación y competencias relacionadas con la detección automática de desinformación mediante evidencia textual.

Descripción del dataset

El objetivo principal del dataset FEVER es evaluar modelos capaces de determinar si una afirmación es:

- **Verdadera (*Supported*)**: La afirmación está respaldada por evidencia textual.
- **Falsa (*Refuted*)**: La afirmación es contradicha por evidencia textual.
- **Insuficiente (*Not Enough Info*)**: No hay suficiente información en el corpus para verificar la afirmación.

El dataset cuenta con las siguientes características:

- **145,000 afirmaciones anotadas** manualmente.
- **5.4 millones de documentos de Wikipedia** utilizados como corpus de evidencia.
- **Estructura de las afirmaciones**: Se generaron a partir de oraciones extraídas de Wikipedia, permitiendo tanto la verificación como la refutación de hechos mediante evidencia textual.

Las afirmaciones que componen el dataset fueron generadas a partir del volcado de Wikipedia correspondiente a junio de 2017. Para el procesamiento del texto se utilizó la herramienta Stanford CoreNLP. A partir de este corpus, se seleccionaron oraciones provenientes de las secciones introductorias de aproximadamente 50,000 páginas consideradas populares.

Durante el proceso de anotación, se asignaron a los anotadores oraciones seleccionadas aleatoriamente, con la tarea de generar afirmaciones centradas en un solo hecho relevante, enfocado principalmente en la entidad principal del artículo correspondiente. Con el fin de incrementar la complejidad y evitar la generación de afirmaciones triviales, se utilizó un diccionario de términos clave junto con hipervínculos a otras páginas de Wikipedia. Esta estrategia permitió a los anotadores incorporar información contextual o relacionada que enriqueciera las afirmaciones.

Además de producir afirmaciones originales, los anotadores generaron versiones modificadas conocidas como mutaciones. Estas mutaciones alteraban el significado de la afirmación original mediante diversas técnicas, como el parafraseo, la negación, la sustitución de entidades o relaciones, y la generalización o especificación. Estas transformaciones fueron diseñadas para evaluar la robustez del sistema frente a variaciones semánticas y estructurales del lenguaje.

Esto permitió obtener afirmaciones con distintos grados de dificultad para los modelos de verificación.

En el proceso de evaluación, se aplicaron rigurosos criterios de calidad para garantizar la fiabilidad de los datos. Se descartó el 1.01 % de las afirmaciones debido a problemas de calidad, mientras que un 6 % adicional fue excluido por considerarse ambiguo. La validación de las etiquetas se llevó a cabo mediante un esquema de five-way agreement complementado con la revisión de super annotators. Como resultado, se alcanzó un coeficiente kappa de Fleiss de 0.68, valor que se encuentra cerca del umbral recomendado de 0.70, lo que indica un nivel aceptable de concordancia entre anotadores. Además, en la evaluación realizada exclusivamente por los super annotators, se obtuvo una precisión del 95 % y un recall del 72 %, lo que refleja un desempeño sólido en la identificación correcta de las afirmaciones.

La Figura 3.1 muestra cuatro gráficas relacionadas con el conjunto de entrenamiento: media de tokens por clase, distribución de *claims* verificables y no verificables por clase, media del número de evidencias por clase y distribución de las etiquetas. Se observa que la media de tokens por *claim* es de 9 tokens. Los *claims* de la clase *Not enough info* no son verificables porque no tienen evidencias asociadas, mientras que los *claims* de las clases *refutes* y *supports* tienen una media de dos evidencias. En cuanto a la distribución de clases, el conjunto de entrenamiento presenta una clase dominante (*supports*, con 80,000 muestras), mientras que *not enough info* y *refutes* cuentan con aproximadamente 35,000 y 30,000 muestras, respectivamente.




Figura 3.1: Visualización del conjunto de entrenamiento respecto la media de *tokens* por clase, distribución verificable por clase, media de evidencias por clase y distribución de etiquetas

Por otro lado, la Figura 3.2 muestra gráficas similares correspondientes al conjunto de validación. Cabe destacar la distribución de clases: mientras que el conjunto de entrenamiento presenta un desbalance de clases, el conjunto de validación está completamente balanceado, con aproximadamente 9,000 muestras por clase.




Figura 3.2: Visualización del conjunto de validación respecto la media de *tokens* por clase, distribución verificable por clase, media de evidencias por clase y distribución de etiquetas

Capítulo 4

Implementación y desarrollo

4.1 Preprocesado. Codificación de Embeddings

Antes de alimentar el sistema con información textual, se realiza una etapa de preprocesado que transforma tanto los *claims* como los documentos del corpus en representaciones vectoriales adecuadas para tareas posteriores de inferencia. Para ello, se utiliza el modelo BAAI/bge-small-en-v1.5, perteneciente a la familia BGE (BAAI General Embeddings).

BGE es una serie de modelos desarrollados por la *Beijing Academy of Artificial Intelligence* (BAAI), diseñados específicamente para tareas de recuperación de información, clasificación semántica y búsqueda textual. Estos modelos están optimizados para generar embeddings que capturan con alta precisión la similitud semántica entre textos, y constituyen una alternativa eficiente y competitiva frente a modelos como *Sentence-BERT*. El código fuente está disponible públicamente en GitHub¹.

El modelo `bge-small-en-v1.5`² se basa en la arquitectura RoBERTa y ha sido entrenado mediante aprendizaje contrastivo con tripletas de entrenamiento (`query`, `positive_doc`, `negative_doc`). Este enfoque permite que el modelo aprenda a representar de forma cercana en el espacio vectorial a los textos semánticamente relacionados, y a distanciar aquellos no relacionados. El objetivo es facilitar la comparación y el ranking de documentos en función de su relevancia respecto a una consulta.

Este modelo ha demostrado un alto rendimiento en el **Massive Text Embedding Benchmark (MTEB)**[9], un benchmark diseñado para evaluar la calidad de embeddings en 8 tareas diferentes (clasificación, clustering, recuperación, re-ranking, etc.), más de 58 datasets y 112 idiomas. MTEB proporciona una evaluación exhaustiva y realista del desempeño de modelos de texto en múltiples dominios y escenarios, permitiendo así identificar soluciones óptimas para tareas específicas como la recuperación de evidencia.

En este trabajo, se ha optado por utilizar el modelo sin aplicar *fine-tuning*, generando los embeddings directamente a partir de los textos originales tanto de *claims* como de cada

¹Repositorio oficial de BGE: <https://github.com/FlagOpen/FlagEmbedding>

²Modelo en Hugging Face: <https://huggingface.co/BAAI/bge-small-en>

documento de Wikipedia de FEVER. Todos estos embeddings se han almacenado en un dataset accesible a través de Hugging Face Datasets³

4.2 Arquitectura




Figura 4.1: Arquitectura del sistema de verificación de desinformación usando IR y NLI con adaptación LoRA y recuperación de información

4.2.1 Módulo 1. Information Retrieval

El módulo de *Semantic Information Retrieval* (SIR, por sus siglas en inglés) constituye la primera etapa en la arquitectura diseñada para la verificación de desinformación. Su objetivo principal es recuperar fragmentos de texto relevantes de un corpus amplio (en este caso, Wikipedia) que puedan servir como evidencia para confirmar o refutar un *claim* (afirmación). Esta etapa se basa en transformar tanto los *claims* como los documentos del corpus en representaciones vectoriales (embeddings), de manera que sea posible medir la similitud semántica entre ellos.

Una recuperación efectiva de evidencia es crucial para el desempeño global del sistema, ya que los resultados generados por este módulo alimentan directamente al segundo módulo de la arquitectura: el de *Inferencia del Lenguaje Natural* (NLI, por sus siglas en inglés "Natural

³Dataset preprocesado: <https://huggingface.co/datasets/JORGEDC01/Demo1>

Language Inference"). En este sentido, la calidad de los documentos recuperados impacta directamente en la precisión del sistema en su conjunto.

Primera aproximación: recuperación basada en FEVER

En esta primera aproximación, el módulo de *Information Retrieval* no realiza búsquedas activas ni aplica mecanismos de recuperación semántica en tiempo real. En su lugar, se parte directamente de la información proporcionada por el dataset FEVER, concretamente de los *claims* y sus evidencias asociadas, procesadas previamente mediante embeddings (ver Sección 4.1).

El dataset FEVER ya incluye, para cada afirmación, una o varias evidencias en forma de frases extraídas de páginas de Wikipedia que permiten verificar o refutar el hecho planteado. En promedio, cada *claim* está vinculado a 2 documentos de Wikipedia. Esta información es suficiente para evaluar el rendimiento básico de modelos inferenciales, pero no simula los entornos reales abiertos donde existe una gran cantidad de información irrelevante.

Para abordar este desafío, se introducen explícitamente **distractores**: documentos irrelevantes que no guardan relación con el *claim*, pero cuya estructura textual es comparable. Este ruido simulado fuerza al modelo a identificar las evidencias verdaderamente relevantes entre múltiples opciones, construyendo un entorno real de recuperación de información.

La estrategia de generación de distractores se basa en una selección **aleatoria y balanceada** de textos embebidos previamente a partir de páginas de Wikipedia no relacionadas. Se seleccionan 3 distractores por cada *claim*, repartidos de forma uniforme entre los archivos del corpus para evitar sesgos de origen. Este proceso se ha implementado garantizando diversidad en la procedencia de los distractores y evitando que provengan de las mismas fuentes que las evidencias.

- Para cada *claim*, se conservan sus evidencias correctas tal y como aparecen en FEVER.
- Se añaden 3 embeddings adicionales como distractores, seleccionados aleatoriamente del conjunto completo de embeddings de Wikipedia.
- Se asegura que ningún distractor pertenezca a las mismas páginas que las evidencias del *claim*.

El resultado es un dataset enriquecido con ruido controlado, donde cada muestra contiene:

- Embedding del **claim**.
- Embeddings de **evidencias relevantes**.
- Embeddings de **distractores irrelevantes**.

Este nuevo dataset también ha sido almacenado en Hugging Face Datasets⁴, y se utiliza como entrada directa para los experimentos de inferencia sin recuperación semántica activa. Esta aproximación permite evaluar la capacidad del modelo de lenguaje para identificar evidencia entre ruido, sirviendo como base comparativa para versiones posteriores del sistema que sí

⁴Disponible en: <https://huggingface.co/datasets/JORGEDC01/Demo1>

incorporarán un módulo de recuperación semántica.

Desde un punto de vista arquitectónico, esta decisión permite desacoplar el módulo de recuperación de la lógica de inferencia, facilitando una primera evaluación aislada del comportamiento del modelo de inferencia del lenguaje natural. Es decir, el sistema puede centrarse exclusivamente en evaluar si, dadas ciertas representaciones vectoriales (*claim* + evidencias + distractores), es capaz de determinar correctamente la veracidad de una afirmación, sin que entren en juego posibles errores de recuperación en la búsqueda.

Este enfoque sirve como línea base y punto de partida para los siguientes experimentos, en los que se incorporará una búsqueda semántica real en esta etapa. La separación clara de módulos también contribuye a una evaluación modular del sistema completo, útil en entornos experimentales.

Segunda aproximación: Recuperación semántica (SIR) con FAISS

En esta segunda aproximación, se introduce un módulo de recuperación de información semántica basado en la biblioteca **FAISS** (Facebook AI Similarity Search), con el objetivo de simular entornos más realistas en los que la información relevante no está directamente disponible, sino que debe localizarse a partir de un gran corpus de documentos.

A diferencia de la primera versión del sistema, donde se partía directamente de las evidencias proporcionadas por el dataset *FEVER*, en esta fase se eliminan estas evidencias iniciales y se sustituye su recuperación por un proceso automático que selecciona, para cada *claim*, los fragmentos de texto más cercanos semánticamente desde un índice vectorial previamente construido.

Se parte de un conjunto de páginas de Wikipedia previamente codificadas utilizando el encoder **BGE**. Estos vectores se almacenan en disco y se organizan en un índice de FAISS utilizando la clase `IndexFlatIP`, que emplea el producto escalar (*dot product*) como métrica de búsqueda.

Sin embargo, dado que el objetivo es medir la **similitud coseno**, la cual es más apropiada para embeddings semánticos, se normalizan todos los vectores a norma $L2 = 1$. Esta operación transforma el producto escalar en una métrica equivalente a la similitud coseno, garantizando que el índice recupere los vectores más cercanos en términos de dirección y no simplemente por magnitud.

Una vez generado el índice, se utiliza para recuperar automáticamente las evidencias más cercanas a cada *claim* del conjunto de test. Solo se procesan aquellos *claims* verificables, es decir, aquellos que en la anotación original del dataset *FEVER* contienen evidencias válidas. Los *claims* etiquetados como “Not Enough Info” (NEI) se excluyen de esta fase, dado que no hay evidencia objetiva con la cual comparar.

En la Figura 4.2 se ilustra la recuperación de evidencias para los *claims*. Para cada *claim*, se codifica su texto con el mismo modelo BGE y se normaliza su embedding. A continuación, se realiza una búsqueda en el índice FAISS para recuperar las **$k = 2$ evidencias** más próximas en el espacio vectorial, imitando la cantidad típica de evidencias proporcionadas en el dataset *FEVER*.




Figura 4.2: Sistema de recuperación de información con FAISS

Este enfoque permite reemplazar las evidencias originales por aquellas que han sido encontradas mediante recuperación por similitud semántica.

4.2.2 Modulo 2. Inferencia del Lenguaje Natural (NLI)

Del primer módulo de *information retrieval* se obtienen los *embeddings* contextuales generados por el modelo BGE (de dimensión 384), los cuales sirven como entrada para el modelo de inferencia basado en un LLM de la familia LLaMA.

Como se puede observar en la Figura 4.3, la arquitectura del modelo de clasificación se compone de los siguientes elementos:

- Una **capa lineal de proyección** que transforma los *embeddings* del BGE al espacio latente del modelo LLaMA correspondiente. En concreto, los tamaños de proyección dependen del modelo utilizado: LLaMA3.2-1B (2048), LLaMA3.2-3B (3072) y LLaMA3.1-8B (4096).
- El **modelo LLaMA** actúa como decodificador, recibiendo los *inputs_embeds* proyectados y generando una secuencia de estados ocultos. Se activa la opción *output_hidden_states=True* para recuperar la salida de todas las capas internas.
- Se selecciona el **último estado oculto** (`hidden_states[-1]`), correspondiente a la salida del último bloque de atención del modelo, sobre el cual se aplica una operación de *pooling* por suma a lo largo de la dimensión temporal (tokens), agregando así la información global de la secuencia.
- Finalmente, se aplica una **capa lineal de clasificación** sobre la representación agregada, precedida por un *dropout* del 30 % para regularización. Esta capa predice una de las tres clases posibles mediante una función **softmax** implícita en la función de pérdida.




Figura 4.3: Arquitectura del módulo NLI

En este módulo se busca explotar el rendimiento de los modelos grandes de lenguaje (LLM) de la familia **LLaMA**. El primer modelo de esta familia fue lanzado por *Meta AI* en 2023, con el objetivo de construir modelos eficientes priorizando el tamaño del modelo frente al tamaño del corpus de entrenamiento. En lugar de incrementar masivamente la cantidad de datos, los diseñadores se centraron en escalar el rendimiento mediante el aumento del número de parámetros.

En esta línea de investigación, se hace uso de tres variantes de la familia LLaMA:

- **LLaMA 3.2 (1B)**, con aproximadamente 1.000 millones de parámetros.
- **LLaMA 3.2 (3B)**, con aproximadamente 3.000 millones de parámetros.
- **LLaMA 3.1 (8B)**, con aproximadamente 8.000 millones de parámetros.

Se seleccionan modelos de diferentes tamaños con el fin de evaluar la estabilidad y consistencia de los resultados obtenidos bajo una misma arquitectura base.

Sin embargo, los LLM actuales presentan un desafío importante: **el elevado consumo de memoria**. Durante el entrenamiento, no solo deben almacenarse los pesos del modelo, sino también sus gradientes, lo que implica el uso de hasta el doble de memoria respecto al tamaño de los pesos. Por ejemplo, entrenar un modelo de 6 GB puede requerir hasta 12 GB de memoria efectiva.

Para mitigar este problema, en este trabajo se recurre a los modelos **cuantizados en 4 bits de Unsloth**. *Unsloth* es una iniciativa orientada a acelerar el entrenamiento y la inferencia

de LLMs mediante técnicas como la cuantización y la fusión de capas, ofreciendo modelos compatibles con el ecosistema Hugging Face. La cuantización a 4 bits reduce drásticamente el tamaño del modelo (hasta un 75 % de reducción), permitiendo entrenar modelos grandes en hardware más limitado.

En la Tabla 4.1 se comparan los requisitos de almacenamiento entre los modelos originales de Meta (en precisión completa) y las versiones cuantizadas ofrecidas por Unsloth:

Tabla 4.1: Comparativa de almacenamiento entre modelos LLaMA y versiones cuantizadas de Unsloth

Model	Params	Original (16fp, Meta)	Quantized (4bit, Unsloth)
LLaMA 3.2 - 1B	1.000M	2 GB	0.5 GB
LLaMA 3.2 - 3B	3.000M	6 GB	1.5 GB
LLaMA 3.1 - 8B	8.000M	18 GB	4.5 GB

Gracias a esta reducción significativa en el tamaño del modelo, ha sido posible entrenar y ajustar estos modelos mediante técnicas como *LoRA*.

Fine-tuning con LoRA

Con el objetivo de adaptar los modelos de lenguaje LLaMA utilizados en este trabajo a la tarea específica de verificación de hechos, se ha empleado la técnica de *Low-Rank Adaptation* (LoRA), propuesta por Microsoft [5]. Esta técnica permite realizar un *fine-tuning* eficiente de modelos de gran tamaño, reduciendo significativamente los requisitos de memoria y computación.

En lugar de actualizar todos los pesos del modelo base, LoRA congela estos pesos originales y entrena únicamente un pequeño conjunto de matrices adicionales de bajo rango (A y B) que se introducen en puntos específicos del modelo. Estas matrices permiten simular el efecto del ajuste completo de los pesos durante la inferencia, pero con una fracción del coste computacional. Además, el número de parámetros entrenables se reduce drásticamente, lo que facilita el ajuste incluso en entornos con recursos limitados.

En este trabajo, se aplica LoRA sobre tres modelos de la familia LLaMA: 1B, 3B y 8B parámetros. El *fine-tuning* se realiza sobre el módulo de inferencia del sistema, tanto en el enfoque sin recuperación activa (basado directamente en evidencias del dataset FEVER), como en el enfoque con recuperación semántica (basado en la búsqueda de documentos relevantes en el espacio vectorial).

Comparativa con y sin LoRA

Para evaluar el impacto del uso de LoRA en la capacidad de los modelos para realizar inferencia lógica sobre afirmaciones (*claims*) y documentos (*evidencias*), se realiza una comparativa directa en ambos enfoques de inferencia:

- **Inferencia basada en evidencias predefinidas (sin recuperación semántica):**
En esta configuración, se compara el rendimiento del modelo original (preentrenado, sin ajuste con LoRA) con el modelo ajustado mediante LoRA, utilizando un conjunto fijo de evidencias provenientes del dataset de FEVER, al que se han añadido distractores

previamente. El objetivo es evaluar el impacto del ajuste fino con LoRA en la capacidad de inferencia del modelo, manteniendo constantes las evidencias.

- **Inferencia basada en recuperación semántica (con recuperación):** En esta segunda comparativa, se analiza el impacto del módulo de recuperación de información semántica en el rendimiento del sistema. Para ello, se comparan modelos ajustados con LoRA: uno basado únicamente en evidencias fijas del dataset de FEVER, y otro que incorpora un módulo de recuperación automática mediante búsqueda vectorial. Esta evaluación permite medir en qué medida la integración de recuperación semántica mejora la capacidad del modelo para seleccionar e interpretar correctamente las evidencias relevantes.

Esta comparativa tiene como objetivo estudiar no solo la ganancia de rendimiento que puede aportar LoRA en tareas de inferencia específicas, sino también observar si esta mejora es consistente en ambos escenarios: cuando las evidencias son proporcionadas directamente y cuando deben ser recuperadas por el sistema.

4.2.3 Interacción entre módulos

El sistema automático de verificación de *claims* está compuesto principalmente por dos módulos: *Information Retrieval* (IR) y *Natural Language Inference* (NLI). La interacción entre estos módulos es fundamental para el funcionamiento del sistema.

En primer lugar, el módulo IR recibe como entrada la afirmación o *claim* en lenguaje natural y recupera de una base de datos (un corpus de documentos confiables) un conjunto de evidencias relevantes que puedan respaldar o contradecir dicha afirmación. Este conjunto de evidencias es luego pasado junto con la afirmación al módulo NLI.

El módulo NLI utiliza modelos de lenguaje profundo entrenados para inferir la relación entre la afirmación y cada evidencia recuperada. El resultado es una etiqueta que clasifica la relación en una de tres categorías: *SUPPORTED*, *REFUSES* o *NOT ENOUGH INFO*.

Para coordinar ambos módulos y lograr un sistema integrado, se sigue el siguiente esquema:

- El módulo IR prioriza la recuperación de documentos con alta relevancia semántica mediante técnicas de búsqueda avanzada y ranking.
- El módulo NLI procesa cada par *afirmación-evidencia* y genera una puntuación de confianza para cada clase.
- Finalmente, se aplica una agregación (por ejemplo, votación mayoritaria o combinación ponderada de puntuaciones) para decidir la etiqueta final asignada a la afirmación.

Respecto a la función de pérdida utilizada durante el entrenamiento del módulo NLI, se emplea la función **Cross-Entropy Loss**, dada la naturaleza de clasificación multiclase (tres clases). Esta función permite que el modelo aprenda a asignar probabilidades altas a la clase correcta y bajas a las incorrectas, optimizando la capacidad de inferencia semántica.

La coordinación entre módulos permite un sistema escalable y modular, donde mejoras en el módulo IR o en el NLI pueden incorporarse sin afectar la estructura global.

4.3 Entrenamiento y configuración de hiperparámetros

En esta sección se describen los hiperparámetros utilizados en los diferentes experimentos de entrenamiento del módulo de inferencia. Se realizan pruebas tanto con modelos LLaMA sin ajustes adicionales como con modelos ajustados mediante la técnica de *Low-Rank Adaptation* (LoRA). Todos los entrenamientos se llevan a cabo sobre el nuevo *dataset* creado con evidencias verdaderas y distractores generados en la fase de preprocesamiento.

Elección del Optimizador

Para el entrenamiento de los modelos de inferencia, se ha utilizado el optimizador **AdamW**, una variante del optimizador Adam que desacopla el término de *weight decay* de la actualización de los momentos, lo cual mejora la generalización en tareas de *fine-tuning*. Esta elección responde a su eficacia demostrada en el entrenamiento de modelos de gran escala y a su adopción como estándar en la mayoría de marcos de trabajo modernos como PyTorch y Hugging Face. En todos los experimentos realizados —tanto con como sin LoRA— se mantiene AdamW como optimizador base, ajustando únicamente los valores de *learning rate*, *weight decay* y *betas* según el modelo y configuración concreta.

Modelos sin LoRA

En los experimentos sin ajuste fino, se utilizan modelos LLaMA directamente como decodificadores con sus pesos preentrenados. La Tabla 4.2 resume los valores utilizados para cada configuración.

Tabla 4.2: Hiperparámetros de entrenamiento sin LoRA

Modelo	LR	Batch size	Dropout	Epochs	Patience	Optim.
LLaMA 3.2 - 1B	$3 \cdot 10^{-5}$	128	0.3	15	5	AdamW
LLaMA 3.2 - 3B	$3 \cdot 10^{-5}$	64	0.3	15	5	AdamW

El optimizador utilizado en ambos casos es AdamW con `weight_decay = 1e-2` y `betas = (0.9, 0.95)`.

Modelos ajustados con LoRA

Para los experimentos con ajuste fino, se utiliza la técnica LoRA sobre modelos cuantizados en 4 bits, ofrecidos por la librería *Unsloth*. En la Tabla 4.3 se recogen los hiperparámetros utilizados, incluyendo los específicos de LoRA.

Tabla 4.3: Hiperparámetros de entrenamiento con LoRA

Modelo	LR	Batch	Drop.	Epochs	Pat.	r	α	Lora Drop.
LLaMA 3.2 - 1B	$3 \cdot 10^{-4}$	128	0.3	15	5	4	16	0.1
LLaMA 3.2 - 3B	$3 \cdot 10^{-4}$	128	0.3	15	5	8	32	0.2
LLaMA 3.1 - 8B	$6 \cdot 10^{-4}$	128	0.3	15	5	10	64	0.05

El optimizador utilizado en estos casos es también AdamW, con `weight_decay` igual a 1×10^{-4} para los modelos de 1B y 3B, y 1×10^{-5} para el de 8B, además de `betas = (0.9, 0.95)`.

El modelo LLaMA 3.1 de 8B únicamente se entrena con LoRA debido a sus altos requisitos de memoria.

4.3.1 Particionamiento de datos

Para evaluar de forma rigurosa los modelos de verificación de hechos, el conjunto de datos se ha dividido en tres subconjuntos mutuamente excluyentes:

- **Entrenamiento (train)**: utilizado para ajustar los parámetros del modelo durante el proceso de aprendizaje.
- **Validación (val)**: utilizado para la selección de hiperparámetros y técnicas de regularización.
- **Prueba (test)**: utilizado exclusivamente para evaluar el rendimiento final del modelo.

Este particionamiento corresponde a la **primera aproximación de recuperación de información**, en la que las evidencias asociadas a cada afirmación provienen directamente del dataset FEVER, y los distractores han sido añadidos durante el preprocesado. El particionamiento se ha realizado de forma que cada página de Wikipedia aparece únicamente en uno de los subconjuntos, lo cual evita que el modelo memorice evidencias vistas durante el entrenamiento.

Tabla 4.4: Distribución del dataset por partición (primera aproximación sin módulo SIR)

Partición	Tamaño	Características
Train	50,907	label, claim, claim_embedding, evidence, distractors
Validation	10,000	label, claim, claim_embedding, evidence, distractors
Test	9,998	label, claim, claim_embedding, evidence, distractors

En la **segunda aproximación de recuperación semántica** (véase el apartado 4.2.1 Segunda aproximación), se reutiliza el conjunto de prueba (9,998), pero las evidencias no provienen del dataset original. En su lugar, se generan automáticamente mediante un módulo de recuperación de información basado en similitud semántica. En este caso, las instancias del conjunto de test contienen exclusivamente las siguientes características:

Tabla 4.6: Características del conjunto de prueba (segunda aproximación con módulo SIR)

Partición	Características
Test (segunda aproximación)	claim_embedding, retrieved_evidence_embedding, distractors_embedding

4.3.2 Métricas de evaluación

Para evaluar el rendimiento de la arquitectura propuesta, se emplean métricas tanto de clasificación como de recuperación, estructuradas en dos niveles: el rendimiento del modelo de inferencia y la calidad de la recuperación de evidencia.

1. Métricas de clasificación (sobre etiquetas):

Se utilizan las métricas estándar de clasificación multiclase: **accuracy**, **precision**, **recall** y **F1-score**. Estas se aplican sobre las etiquetas predichas por el modelo (SUPPORTS, REFUTES y NOT ENOUGH INFO), comparándolas con las etiquetas reales del conjunto de test.

- **Accuracy**: proporción de predicciones correctas sobre el total de ejemplos evaluados.
- **Precision**: proporción de predicciones positivas correctas frente al total de predicciones positivas realizadas.
- **Recall**: proporción de ejemplos positivos correctamente predichos frente al total de positivos reales.
- **F1-score**: media armónica entre precisión y recall, útil especialmente en conjuntos de datos desbalanceados.

2. Métrica de evaluación de la recuperación de evidencia:

Para evaluar la calidad de la evidencia recuperada, se utiliza la métrica *FEVER Score*, en su variante oficial [14]:

- **FEVER Score oficial**: se calcula para comparar el rendimiento del sistema con los resultados reportados en el estado del arte (SOTA). Esta métrica, definida en el benchmark original de FEVER, considera que una predicción es válida únicamente si:
 - La etiqueta predicha es correcta.
 - Y, si la etiqueta es SUPPORTS o REFUTES, al menos uno de los documentos que contienen la evidencia real (documentos dorados) ha sido recuperado correctamente, comparando mediante similitud de embeddings.

Esta métrica, más estricta, permite establecer comparaciones directas con los sistemas más avanzados reportados en la literatura.

Estas métricas permiten evaluar tanto la capacidad del modelo para clasificar correctamente las afirmaciones como su habilidad para justificar dichas predicciones mediante la evidencia precisa.

4.3.3 Experimentos y comparaciones

Los experimentos se estructuran en dos fases principales, diferenciadas por la incorporación o no del módulo de recuperación semántica (SIR). Para facilitar su identificación visual, los grupos comparables se han resaltado con colores en la Tabla 4.8:

- **Fase 1 – Evaluación del Módulo de Inferencia con y sin ajuste fino (sin Recuperación Semántica de Información, SIR):**
 - Se comparan los modelos 1B-base-fixed con 1B-lora-fixed (filas en **verde claro**), 3B-base-fixed con 3B-lora-fixed (filas en **azul claro**), y 8B-base-fixed con 8B-lora-fixed (filas en **amarillo claro**).
 - Estas comparaciones permiten analizar el impacto del ajuste fino mediante LoRA sobre el rendimiento inferencial, manteniendo constante el conjunto de evidencias proporcionado (extraído del dataset FEVER con distractores).
- **Fase 2 – Evaluación del impacto del módulo de recuperación de información (SIR) sobre el rendimiento del módulo de inferencia:**
 - En esta fase, se comparan los modelos ajustados mediante LoRA de la Fase 1 (1B-lora-fixed, 3B-lora-fixed, 8B-lora-fixed) con sus versiones que incorporen recuperación semántica automática (1B-lora-retrieved, 3B-lora-retrieved, 8B-lora-retrieved) — resaltadas en **naranja claro**.
 - Esta comparación permite evaluar el efecto de utilizar recuperación vectorial para seleccionar evidencias relevantes, y cómo esto influye en la capacidad de inferencia factual de los modelos previamente afinados.

ID Experimento	Fase	Modelo	LoRA	Recuperación Semántica
1B-base-fixed	1	LLaMA 3.2 - 1B	No	No
1B-lora-fixed	1	LLaMA 3.2 - 1B	Sí	No
3B-base-fixed	1	LLaMA 3.2 - 3B	No	No
3B-lora-fixed	1	LLaMA 3.2 - 3B	Sí	No
8B-base-fixed	1	LLaMA 3.1 - 8B	No	No
8B-lora-fixed	1	LLaMA 3.1 - 8B	Sí	No
1B-lora-retrieved	2	LLaMA 3.2 - 1B	Sí	Sí
3B-lora-retrieved	2	LLaMA 3.2 - 3B	Sí	Sí
8B-lora-retrieved	2	LLaMA 3.1 - 8B	Sí	Sí

Tabla 4.8: Resumen de los experimentos realizados. Las filas coloreadas agrupan los modelos que se comparan directamente. En la Fase 1 se estudia el impacto de LoRA sin recuperación semántica. En la Fase 2 se evalúa el efecto de incorporar recuperación semántica sobre modelos ajustados con LoRA.

Capítulo 5

Resultados

5.1 Resultados 1º Fase: Evaluación del módulo de inferencia con y sin LoRA (sin recuperación semántica)

En esta fase se presentan los resultados de los experimentos realizados sin utilizar recuperación semántica, es decir, trabajando exclusivamente con un conjunto fijo de evidencias (provenientes del dataset FEVER con distractores incluidos). El objetivo principal es evaluar el impacto del ajuste fino mediante LoRA sobre los modelos base.

Se comparan dos arquitecturas de modelos de lenguaje: Llama-3.2 de 1B y Llama-3.2 de 3B, tanto en su versión original (sin LoRA) como en su versión ajustada con LoRA. Para cada configuración se realizaron **tres ejecuciones independientes** con distintas semillas, a fin de medir la consistencia y estabilidad del entrenamiento, así como obtener métricas promedio robustas.

Cabe destacar que en esta fase **no se incluye el modelo Llama-3.1 de 8B sin LoRA**, ya que por limitaciones de hardware y eficiencia computacional, solo se evaluó este modelo en su versión con ajuste fino (LoRA).

Los resultados obtenidos permiten comparar directamente el efecto del uso de LoRA sobre el rendimiento de los modelos, en condiciones controladas y sin la influencia de un módulo de recuperación semántica.

5.1.1 Evaluación sin LoRA

En esta sección se presentan los resultados obtenidos por los modelos base, es decir, aquellos que no han sido sometidos a un proceso de ajuste fino mediante LoRA. El objetivo principal es establecer una línea base de rendimiento para evaluar la capacidad de inferencia de los modelos sin intervención adicional. Para ello, se han utilizado los modelos Llama-3.2-1B y Llama-3.2-3B, ambos entrenados utilizando un conjunto de evidencias fijas, sin recuperación semántica ni expansión de contexto. Esta configuración permite observar el comportamiento de los modelos en condiciones controladas y sirve como punto de comparación para posteriores

experimentos con técnicas de adaptación más avanzadas.

La columna *Epochs* indica la última *epoch* alcanzada durante el entrenamiento antes de activarse el criterio de parada temprana (*EarlyStopping*), configurado con un máximo de 15 *epochs*. La columna $T(min)$ muestra la duración total del entrenamiento, en minutos, hasta alcanzar dicha *epoch*.

Llama-3.2-1B

La Tabla 5.1 muestra los resultados obtenidos por el modelo Llama-3.2-1B sin LoRA en cada una de las tres ejecuciones.

Tabla 5.1: Resultados de las ejecuciones con Llama-3.2-1B-bnb-4bit sin LoRA

Ejecución	Epochs (15)	Accuracy	Precisión	Recall	F1-score	T(min)
1	11	0.7220	0.7292	0.7220	0.7135	33.51
2	14	0.7283	0.7452	0.7283	0.7153	42.64
3	14	0.7302	0.7549	0.7302	0.7168	42.91

La Figura 5.1 presenta la matriz de confusión del mejor modelo sin LoRA (correspondiente a la ejecución 3 con Llama-3.2-1B), que permite observar la distribución de errores entre las clases.




Figura 5.1: Matriz de confusión del mejor modelo sin LoRA (Llama-3.2-1B)

Llama-3.2-3B

La Tabla 5.2 presenta los resultados para el modelo Llama-3.2-3B sin LoRA, con las tres ejecuciones independientes.

Tabla 5.2: Resultados de las ejecuciones con **Llama-3.2-3B-bnb-4bit** sin LoRA

Ejecución	Epochs (15)	Accuracy	Precisión	Recall	F1-score	T(min)
1	8	0.7329	0.7601	0.7329	0.7170	57.58
2	8	0.7453	0.7557	0.7453	0.7373	57.76
3	8	0.7336	0.7647	0.7336	0.7131	57.67

La Figura 5.2 muestra la matriz de confusión del mejor modelo sin LoRA correspondiente a la ejecución 3 del modelo Llama-3.2-3B.




Figura 5.2: Matriz de confusión del mejor modelo sin LoRA (Llama-3.2-3B)

Comparativa general entre modelos sin LoRA

La Tabla 5.3 muestra los resultados promedio y desviación estándar de ambas configuraciones sin LoRA, permitiendo comparar su rendimiento global.

Tabla 5.3: Comparación entre modelos sin LoRA: métricas promedio (μ) y desviación estándar (σ)

Modelo	Accuracy	Precisión	Recall	F1-score	T(min)
Llama-3.2-1B	$0,7269 \pm 0,0035$	$0,7431 \pm 0,0106$	$0,7269 \pm 0,0035$	$0,7152 \pm 0,0013$	39.69
Llama-3.2-3B	$0,7373 \pm 0,0057$	$0,7602 \pm 0,0037$	$0,7373 \pm 0,0057$	$0,7225 \pm 0,0106$	57.60

El modelo Llama-3.2-3B sin LoRA supera consistentemente al modelo 1B en todas las métricas evaluadas: accuracy, precisión, recall y F1-score. Aunque las mejoras no son drásticas, sí son sostenidas, destacando un mejor rendimiento general del modelo más grande.

Sin embargo, este mayor desempeño viene con un costo; el tiempo de entrenamiento fue aproximadamente un 46 % mayor.

En conjunto, Llama-3.2-3B es preferible cuando se busca el mejor rendimiento posible y se cuenta con los recursos necesarios, mientras que Llama-3.2-1B representa una opción más eficiente y predecible.

5.1.2 Evaluación con LoRA

En esta sección se presentan los resultados de los modelos ajustados mediante *Low-Rank Adaptation* (LoRA), una técnica de ajuste fino eficiente que permite adaptar modelos grandes a tareas específicas sin necesidad de modificar todos sus parámetros. El objetivo es evaluar el impacto de esta técnica en el rendimiento de modelos previamente preentrenados. Los experimentos fueron realizados con los modelos Llama-3.2-1B, Llama-3.2-3B y Llama-3.1-8B, todos utilizando cuantización de 4 bits y optimización basada en LoRA.

Llama-3.2-1B + LoRA

La Tabla 5.4 resume el desempeño del modelo Llama-3.2-1B entrenado con LoRA.

Tabla 5.4: Resultados del modelo Llama-3.2-1B-bnb-4bit con LoRA

Ejecución	Epochs (15)	Accuracy	Precisión	Recall	F1-score	T(min)
1	15	0.7332	0.7437	0.7332	0.7322	39.36

La Figura 5.3 presenta la matriz de confusión correspondiente al mejor modelo con LoRA para Llama-3.2-1B.




Figura 5.3: Matriz de confusión del modelo Llama-3.2-1B con LoRA

Llama-3.2-3B + LoRA

La Tabla 5.5 muestra los resultados del modelo Llama-3.2-3B ajustado con LoRA.

Tabla 5.5: Resultados del modelo Llama-3.2-3B-bnb-4bit con LoRA

Ejecución	Epochs (15)	Accuracy	Precisión	Recall	F1-score	Tiempo (min)
1	11	0.7491	0.7567	0.7491	0.7421	48.26

La Figura 5.4 presenta la matriz de confusión correspondiente al mejor modelo con LoRA para Llama-3.2-3B.




Figura 5.4: Matriz de confusión del modelo Llama-3.2-3B con LoRA

Llama-3.1-8B + LoRA

La Tabla 5.6 resume los resultados del modelo Llama-3.1-8B con LoRA.

Tabla 5.6: Resultados del modelo Llama-3.1-8B-bnb-4bit con LoRA

Ejecución	Epochs (15)	Accuracy	Precisión	Recall	F1-score	T(min)
1	13	0.7444	0.7622	0.7444	0.7278	117.36

La Figura 5.5 muestra la matriz de confusión para el modelo Llama-3.1-8B tras aplicar LoRA.




Figura 5.5: Matriz de confusión del modelo Llama-2-7B con LoRA

Comparativa general de los modelos con LoRA

La Tabla 5.7 resume los resultados de los tres modelos entrenados con LoRA, permitiendo comparar su rendimiento, considerando tanto el tamaño como el tiempo de entrenamiento.

Tabla 5.7: Comparación entre modelos con LoRA

Modelo	Accuracy	Precisión	Recall	F1-score	T(min)
Llama-3.2-1B	0.7332	0.7437	0.7332	0.7322	39.36
Llama-3.2-3B	0.7491	0.7567	0.7491	0.7421	48.26
Llama-3.1-8B	0.7444	0.7622	0.7444	0.7278	117.36

El modelo Llama-3.2-3B con LoRA muestra el mejor rendimiento en todas las métricas de evaluación, superando tanto al modelo 1B como al 8B, con una diferencia destacada en el F1-score.

Aunque el modelo Llama-3.1-8B es el más grande y muestra una buena precisión, su F1-score es inferior al del modelo 3B y su tiempo de entrenamiento es significativamente mayor (más del doble que el modelo 3B).

En resumen, Llama-3.2-3B con LoRA ofrece el mejor equilibrio entre rendimiento y costo computacional, mientras que Llama-3.2-1B se presenta como una alternativa eficiente con resultados competitivos. Por su parte, Llama-3.1-8B no logra justificar su elevado coste computacional en términos de eficiencia.

5.2 Resultados 2º Fase: Evaluación del impacto del Módulo de IR sobre el Módulo de Inferencia

En esta segunda fase se evalúa el sistema completo de verificación automática, incluyendo el módulo de *Semantic Information Retrieval* (SIR) acoplado al módulo de *Natural Language Inference* (NLI). El objetivo es analizar cómo la calidad de las evidencias recuperadas por SIR afecta el rendimiento global del clasificador.

5.2.1 Evaluación del módulo SIR de forma desacoplada

Para la **evaluación** del rendimiento del módulo SIR se emplea la métrica **Recall** sobre las evidencias recuperadas. La idea es comprobar si, entre las 2 evidencias devueltas por FAISS, al menos una es semánticamente similar a las evidencias reales del dataset. Se toma esta decisión porque una importante cantidad de *claims* incluye solo una evidencia en FEVER.

La evaluación se basa en la **similitud coseno** entre embeddings, utilizando un umbral de 0.9 como criterio de coincidencia. Solo se consideran válidas las muestras que no pertenecen a la clase “Not Enough Info” tanto en la recuperación como en la métrica.

El cálculo final del *recall* refleja la proporción de *claims* para los que al menos una evidencia recuperada supera el umbral de similitud con las evidencias reales.

Los resultados del módulo de recuperación semántica indican un rendimiento sólido. De un total de 9998 muestras en el conjunto de test, 6170 corresponden a *claims* verificables con evidencias asociadas, siendo estas las únicas utilizadas en la evaluación.

El sistema alcanzó un **Recall de 0.8254** con un umbral de similitud coseno de **0.9**, lo que implica que en el **82.54%** de los casos se recuperó al menos una evidencia semánticamente relevante entre las dos más cercanas devueltas por FAISS.

Por último, la evaluación modular del sistema, donde se compara la recuperación semántica respecto a un *ground truth* conocido, permite medir con precisión el impacto del módulo de *IR* de forma aislada, antes de ser acoplado al módulo de inferencia final. Esto permite establecer una base sólida para comparar diferentes estrategias de búsqueda, encoders y arquitecturas de verificación automática de hechos, que se pueden explorar en trabajos futuros.

5.2.2 Evaluación conjunta: SIR + NLI

A continuación se presentan los resultados del modelo Llama-3.2-1B entrenado con LoRA y alimentado con las evidencias recuperadas por el módulo SIR, lo que constituye la arquitectura completa del sistema.


Llama-3.2-1B + LoRA + SIR

La Tabla 5.8 resume el desempeño del modelo completo para la configuración de menor tamaño.

Tabla 5.8: Resultados del modelo Llama-3.2-1B-bnb-4bit con LoRA y SIR

Accuracy	Precisión	Recall	F1-score
0.7469	0.7738	0.7469	0.7465

La Figura 5.6 presenta la matriz de confusión correspondiente al modelo completo con SIR y NLI para Llama-3.2-1B.

**Figura 5.6:** Matriz de confusión del modelo Llama-3.2-1B con LoRA + SIR

Llama-3.2-3B + LoRA + SIR

La Tabla 5.9 muestra los resultados del modelo Llama-3.2-3B ajustado con LoRA y alimentado con las evidencias recuperadas por el módulo SIR.

Tabla 5.9: Resultados del modelo Llama-3.2-3B-bnb-4bit con LoRA y SIR

Accuracy	Precisión	Recall	F1-score
0.7638	0.7886	0.7638	0.7543

La Figura 5.7 muestra la matriz de confusión del modelo completo con SIR y NLI para Llama-3.2-3B.




Figura 5.7: Matriz de confusión del modelo Llama-3.2-3B con LoRA + SIR

Llama-3.1-8B + LoRA + SIR

La Figura 5.8 presenta la matriz de confusión correspondiente al modelo Llama-3.1-8B con LoRA y recuperación semántica.




Figura 5.8: Matriz de confusión del modelo Llama-2-7B con LoRA + SIR

La Tabla 5.10 resume el desempeño del modelo **Llama-3.1-8B** tras aplicar LoRA y utilizar recuperación semántica con SIR.

Tabla 5.10: Resultados del modelo Llama-3.1-8B-bnb-4bit con LoRA y SIR

Accuracy	Precisión	Recall	F1-score
0.7854	0.8084	0.7854	0.7791

5.2.3 Comparativa general de los modelos con LoRA + SIR

La Tabla 5.11 resume los resultados de los tres modelos entrenados con LoRA y evaluados con evidencias obtenidas mediante SIR, permitiendo comparar su rendimiento en el escenario completo del sistema.

Tabla 5.11: Comparación entre modelos con LoRA y SIR

Modelo	Accuracy	Precisión	Recall	F1-score
Llama-3.2-1B	0.7469	0.7738	0.7469	0.7465
Llama-3.2-3B	0.7638	0.7886	0.7638	0.7543
Llama-3.1-8B	0.7854	0.8084	0.7854	0.7791

El modelo **Llama-3.1-8B** con LoRA y SIR obtiene el mejor desempeño global, superando al resto en todas las métricas de evaluación. Su **F1-score** de 0.7791 lo posiciona como el más robusto.

Por su parte, **Llama-3.2-3B** también alcanza resultados sólidos, con una precisión de 0.7886 y un F1-score competitivo (0.7543), lo que lo convierte en una opción intermedia eficaz en cuanto a la relación entre costo computacional y calidad. En cambio, **Llama-3.2-1B** presenta un rendimiento ligeramente inferior en comparación con los modelos más grandes, aunque se mantiene en niveles aceptables (F1-score de 0.7465).

Capítulo 6

Discusión

Este capítulo presenta un análisis crítico de los resultados obtenidos en las diferentes fases experimentales descritas en el apartado Capítulo 4. Implementación y desarrollo 4.3.3. Se busca interpretar el impacto de los distintos componentes del sistema propuesto —como el ajuste fino mediante LoRA y la incorporación de recuperación semántica (SIR)— sobre el rendimiento en la tarea de verificación de hechos. La discusión se organiza en tres secciones principales: en la primera, se analiza el efecto del ajuste fino sobre modelos de diferentes tamaños sin recuperación de información; en la segunda, se estudia cómo la integración del módulo de IR afecta a la capacidad inferencial; y en la tercera, se contextualiza el rendimiento del sistema frente a modelos del estado del arte. A lo largo del capítulo se comparan las métricas obtenidas, se interpretan las diferencias observadas y se discuten posibles causas, limitaciones y oportunidades de mejora.

6.1 1º Fase. Evaluación del módulo de inferencia con y sin ajuste fino (sin recuperación semántica)

Tabla 6.1: Comparación de modelos con y sin LoRA: métricas promedio (μ), desviación estándar (σ) y tiempo de entrenamiento en minutos.

Modelo	LoRA	Accuracy	Precisión	Recall	F1-score	T(min)
Llama-3.2-1B	×	$0,727 \pm 0,004$	$0,743 \pm 0,011$	$0,727 \pm 0,004$	0.715	39.69
Llama-3.2-1B	✓	0.733	0.744	0.733	0.732	39.36
Llama-3.2-3B	×	$0,737 \pm 0,006$	$0,760 \pm 0,004$	$0,737 \pm 0,006$	0.722	57.60
Llama-3.2-3B	✓	0.749	0.757	0.749	0.742	48.26
Llama-3.1-8B	✓	0.744	0.762	0.744	0.728	117.36

En esta primera fase se evaluó el impacto del ajuste fino mediante LoRA sobre el rendimiento inferencial de modelos de lenguaje de la familia **Llama**, manteniendo constante el conjunto de evidencias (extraído del dataset *FEVER* con distractores) y sin incorporar recuperación semántica. Se compararon pares de modelos con y sin LoRA: **Llama-3.2-1B-base** vs. **Llama-3.2-1B-lora** (filas en verde claro), y **Llama-3.2-3B-base** vs. **Llama-3.2-3B-lora** (filas en azul claro). Además, se incluye el modelo **Llama-3.1-8B-lora** (fila en amarillo claro) para

observar el rendimiento de una arquitectura de mayor escala, aunque no se dispone de su contraparte sin LoRA.

Los resultados muestran que la introducción de LoRA mejora sistemáticamente el rendimiento en métricas clave como *accuracy*, *recall* y *F1-score*, manteniendo tiempos de entrenamiento muy similares. Por ejemplo, en la configuración de **1B parámetros**, el F1-score aumenta de **0.715** a **0.732** tras aplicar LoRA, mientras que en el modelo de **3B** se incrementa de **0.722** a **0.742**. Esta mejora sugiere que el ajuste fino mediante LoRA permite una mejor adaptación del modelo a la tarea específica de inferencia sin incurrir en costos adicionales significativos.

En el caso del modelo **Llama-3.1-8B-lora**, a pesar de su mayor tamaño y tiempo de entrenamiento (**117 minutos**), su rendimiento no supera al del modelo **Llama-3.2-3B-lora**, que obtiene métricas superiores en todas las categorías. Por tanto, una mayor escala no garantiza mejores resultados si no se acompaña de una arquitectura más reciente o una mejor sintonización. Dado que se trata de una tarea específica sin un estado del arte definido y sin una búsqueda exhaustiva de hiperparámetros, el modelo aún es susceptible a mejorar en futuros trabajos.

6.2 2º Fase. Evaluación del impacto del Módulo de IR sobre el Módulo de Inferencia

Tabla 6.2: Comparación entre modelos con LoRA sin IR y con IR: métricas y diferencias.

Modelo	Condición	Accuracy	Precisión	Recall	F1-score
Llama-3.2-1B	Sin IR	0.733	0.744	0.733	0.732
Llama-3.2-1B	Con IR	0.747	0.774	0.747	0.746
Diferencia (Con IR - Sin IR)		+0.014	+0.030	+0.014	+0.014
Llama-3.2-3B	Sin IR	0.749	0.757	0.749	0.742
Llama-3.2-3B	Con IR	0.764	0.789	0.764	0.754
Diferencia (Con IR - Sin IR)		+0.015	+0.032	+0.015	+0.012
Llama-3.1-8B	Sin IR	0.744	0.762	0.744	0.728
Llama-3.1-8B	Con IR	0.785	0.808	0.785	0.779
Diferencia (Con IR - Sin IR)		+0.041	+0.046	+0.041	+0.051

En la Tabla 6.2 se presenta una comparación detallada entre los modelos Llama entrenados con LoRA bajo dos condiciones: sin recuperación semántica (*Sin SIR*) y con recuperación semántica integrada (*Con SIR*). Cada par de filas está resaltado con colores diferenciados para facilitar la visualización de las comparaciones por modelo: **verde** para **Llama-3.2-1B**, **cian** para **Llama-3.2-3B** y **amarillo** para **Llama-3.1-8B**.

Los resultados muestran una mejora consistente en todas las métricas clave — *accuracy*, *precisión*, *recall* y *F1-score* — cuando se incorpora la recuperación semántica (IR). Por ejemplo, en el modelo **Llama-3.2-1B**, la precisión aumenta en +0.030, destacándose como la mayor mejora relativa dentro de las métricas evaluadas para este modelo. En el **modelo 3B**, las ganancias son similares pero ligeramente menores, con un incremento máximo de +0.032 en precisión.

El **modelo 8B** muestra las mejoras más pronunciadas en todas las métricas, con un incremento de **+0.051 (+5.1 %)** en F1-score, lo que indica que la recuperación semántica aporta un valor especialmente relevante para las arquitecturas más grandes.

En conjunto, la tabla evidencia que el uso de recuperación semántica complementa eficazmente el ajuste fino con LoRA, mejorando la capacidad inferencial de los modelos sin necesidad de modificar la arquitectura base, y que estos beneficios son progresivamente mayores a medida que el modelo escala en tamaño.

6.3 Comparación con el estado del arte

Con el objetivo de contextualizar el rendimiento del sistema propuesto, se realiza una comparación con modelos representativos del estado del arte (SotA) en tareas de verificación de hechos sobre el dataset *FEVER*. En particular, se han recopilado los valores de **accuracy** y **FEVER Score** reportados por diversos trabajos en la literatura, centrados en el conjunto de test oficial. Los modelos de SotA que se toman como referencia para esta comparación se basan en los reportados en el trabajo de [13].

Modelo	Accuracy (Acc)	FEVER Score (FS)
Ours LLaMA 8B + LoRA + IR	80.84	67.34
Izacard et al. (2022)	80.06	21.29
Guzman-Olivares et al. (2023)	79.69	76.91
Krishna et al. (2022)	79.47	76.82
Jiang et al. (2021b)	79.35	75.87
Fajcik et al. (2022)	79.27	76.45
Stammbach (2021)	79.16	76.68
Ours LLaMA 3B + LoRA + IR	78.86	65.79
Ours LLaMA 1B + LoRA + IR	77.38	63.50
Chen et al. (2022)	75.24	71.17
Zhong et al. (2020)	74.64	71.48
Liu et al. (2020)	74.07	70.38
Zhou et al. (2019)	71.60	67.10

Tabla 6.3: Comparación de modelos ordenados por Accuracy. Los modelos en gris son nuestras variantes LLaMA con LoRA y recuperación semántica (IR).

La Tabla 6.3 presenta el rendimiento del mejor modelo desarrollado en este trabajo (*LLaMA 8B con LoRA e IR semántico*), junto con otras variantes del mismo y una selección de modelos basados en arquitecturas que han liderado el *leaderboard* de FEVER.

Es importante destacar que el *FEVER Score* es una métrica más exigente que la *accuracy*, ya que no solo requiere que la etiqueta asignada sea correcta, sino que también se recupere un conjunto completo de evidencias válidas que sustenten dicha etiqueta. En el sistema propuesto, la recuperación de evidencia se realiza a nivel de documento utilizando embeddings semánticos, lo que permite capturar coincidencias aproximadas más allá de las frases exactas.

Aunque el sistema aún no alcanza los mejores valores de *FEVER Score* reportados en la literatura, estos resultados abren una vía clara de mejora. En particular, existe un margen significativo de optimización mediante la extensión del módulo de recuperación de información (IR) para operar a nivel de frase. Este refinamiento permitiría una identificación más precisa de las evidencias relevantes requeridas por la métrica de FEVER, lo que previsiblemente incrementaría el score manteniendo la eficiencia computacional y la modularidad del sistema.

Capítulo 7

Aspectos Éticos

7.1 Consideraciones Éticas

La desinformación en entornos digitales representa un desafío para la sociedad, afectando a la percepción pública y a la toma de decisiones.

El uso de inteligencia artificial (IA) en la verificación de información no solo se limita a la eficacia técnica del sistema, sino que también plantea importantes cuestiones éticas. La toma de decisiones automatizada en la validación de hechos puede tener un impacto significativo sobre la libertad de expresión, el acceso a la información y la transparencia en los medios de comunicación.

7.2 Impactos Éticos

La implementación de inteligencia artificial (IA) en la detección de desinformación plantea una serie de consideraciones éticas que no pueden ser ignoradas. Desde una perspectiva ética, se deben evaluar estos impactos recurriendo a diferentes teorías éticas, como el utilitarismo, la teoría de la justicia de Rawls y el deontologismo kantiano, para proporcionar un marco en el que se puedan analizar tanto los beneficios como los posibles perjuicios derivados del uso de la IA en la verificación de información.

Desde un punto de vista **utilitarista**, la implementación de IA en la detección de desinformación tiene un claro impacto positivo para la mayoría de la sociedad. La reducción de bulos y noticias falsas permite un mayor acceso a información veraz, aumentando la confianza en los medios de comunicación y evitando la saturación de información engañosa. Además, la protección de la democracia y la estabilidad social se ve fortalecida porque la IA combate la polarización y la manipulación mediática. Estos efectos positivos justifican el uso de la IA en términos de utilidad social, ya que actúa como una herramienta de control que previene el daño causado por la desinformación.

Sin embargo, también existen perjuicios para las minorías, ya que el uso de IA en la detección de desinformación puede implicar un riesgo de censura y sesgo. En este sentido, los algoritmos

de IA podrían amenazar la libertad de expresión de grupos minoritarios. Si los algoritmos interpretan erróneamente ciertas críticas legítimas como desinformación, podrían silenciar voces disidentes. Además, si la IA es controlada por gobiernos o grandes plataformas tecnológicas, podría inclinarse hacia ciertas narrativas dominantes y excluir perspectivas alternativas. Desde una perspectiva utilitarista, si bien la reducción de la desinformación genera un gran beneficio social, el daño potencial a la libertad de expresión de grupos minoritarios representa una amenaza importante.

La **teoría de justicia de Rawls** trata de solventar esta limitación del punto de vista utilitarista. Rawls propone la imparcialidad como base de la justicia. Su concepto de "velo de ignorancia" implica que los principios del sistema deben definirse sin conocer qué grupos de información serán beneficiados o perjudicados. En palabras de Rawls, "la imparcialidad de la situación contractual a la cual él llama posición original se garantiza por un velo de ignorancia que impide a los participantes del acuerdo observar y tener todos los conocimientos particulares, entre ellos los relacionados con su propia identidad y con la sociedad a la cual pertenecen". Un sistema de verificación basado en esta idea debería asegurarse de que no favorezca fuentes específicas por su poder o influencia, que evalúe la información de manera transparente y equitativa, sin sesgos ideológicos o políticos, y que permita la coexistencia de diversas perspectivas, siempre que sean verificables y basadas en evidencia.

Por otro lado, desde el punto de vista **deontológico** de Kant, para que una acción sea ética, debe cumplir con dos principios fundamentales: que sea universal y que trate a las personas como fines en sí mismas, no como medios. En cuanto a la universalidad, un sistema de verificación que opere de manera justa en todos los contextos culturales y políticos, y que funcione sin sesgos mediante reglas claras y justas, sería universalizable. Si el sistema tiene criterios claros y verificables, su funcionamiento podría considerarse ético desde el punto de vista kantiano. No obstante, si el sistema opera como una "caja negra" sin transparencia, se generaría un conflicto ético, ya que los usuarios no sabrían si el sistema es justo o no. Además, se debe cuestionar si las personas están siendo usadas como medios o como fines. Es importante preguntarse si el sistema respeta la autonomía, el libre pensamiento y la actitud crítica de las personas, o si, por el contrario, establece la veracidad de una información como absoluta, sin ofrecer ninguna explicación que permita cuestionarla. En el segundo caso, las personas serían tratadas únicamente como medios y no como fines en sí mismas.

7.3 Ethics by Design en el Desarrollo

El comportamiento ético del sistema IA se garantiza integrando los aspectos éticos en cada una de las fases de desarrollo de un sistema. Estas fases son: especificación de objetivos, especificación de requisitos, diseño de alto nivel, recopilación y preparación de los datos, diseño detallado y desarrollo, y pruebas y validación.

7.3.1 Especificación de objetivos

El objetivo general del proyecto es diseñar un sistema de verificación de desinformación capaz de evaluar las afirmaciones realizadas en un entorno digital. El sistema servirá como

complemento a los fact-checkers en su lucha contra la desinformación.

Los objetivos específicos son:

- Creación de un módulo de Information Retrieval (IR) que sea capaz de recuperar evidencias verificadas provenientes de fuentes confiables.
- Creación de un módulo de Natural Language Inference (NLI) que permita, a través del análisis de evidencias verificadas, evaluar la veracidad de una afirmación presentada en un entorno digital.
- Ser transparentes en el propósito, impacto y beneficio de esta herramienta, que incluye la búsqueda de un entorno digital justo o un aumento en la eficiencia de los trabajadores.
- Diseñar un sistema imparcial, que sea justo y no manipule. Se busca minimizar el sesgo que pueda presentar el modelo.
- Asegurar la seguridad de los datos, debido a la naturaleza de los mismos y las implicaciones en las libertades de los usuarios.

7.3.2 Especificación de requisitos

Los requisitos especificados en el proyecto son:

- Se debe permitir la supervisión humana en la toma de la decisión final.
- Cumplir con los requisitos legales del tratamiento de datos especialmente protegidos (RGPD).
- Permitir que el usuario de la red social acepte la recopilación y el tratamiento de sus datos para la finalidad descrita en este proyecto.
- Reducir el consumo energético mediante LoRA para una optimización eficiente del sistema IA.
- Permitir que los usuarios comprendan el funcionamiento del modelo y la lógica detrás de la toma de decisiones, para proveer al sistema de explicabilidad y transparencia.

7.3.3 Diseño de alto nivel

El mayor riesgo en el diseño del sistema es la desconfianza. Se debe procurar que el sistema no actúe como una "caja negra". Para ello, hay que cumplir con un estándar de transparencia. Se debe especificar la arquitectura del sistema, cómo los módulos trabajan y se comunican entre sí para tomar las decisiones. También se ha licenciado bajo la Licencia Apache 2.0, que permitirá la redistribución del código.

7.3.4 Recopilación y preparación de los datos

Recopilación

Uno de los mayores riesgos a los que se enfrenta el sistema es al sesgo de los datos, lo que puede concurrir en una mala toma de decisiones y afectar a los usuarios. Por ello, se elegirán múltiples fuentes de datos verificadas y abiertas, que ayudarán al modelo a generalizar.

Se llegará a un acuerdo con la red social para que los usuarios puedan consentir de manera explícita en que sus datos sean recopilados y tratados. La información guardada debe ser la estrictamente necesaria para cumplir con la finalidad de este proyecto, lo que incluye el nombre de usuario, su perfil (descripción e imagen de perfil) y las publicaciones realizadas en la red social.

Preparación

Para minimizar un posible riesgo de privacidad de los usuarios y que no sean identificados, se aplican técnicas de anonimización.

Se hará una revisión previa a los datos recopilados de las fuentes verificadas para reducir posibles sesgos y características que puedan afectar gravemente el resultado del sistema. Además, se realiza un balanceo en las declaraciones verificables para garantizar que los datos utilizados estén distribuidos de manera equitativa y representen la realidad.

7.3.5 Diseño detallado y desarrollo

Los datos almacenados se guardarán en un servidor que tendrá cifrado y un control de acceso, para impedir que personas no autorizadas puedan acceder a la información. Por el mismo motivo, la conexión con las fuentes de fact-checking estará cifrada de extremo a extremo.

El sistema también presentará un módulo de explicabilidad para minimizar un riesgo de opacidad. Se tendrá constancia en todo momento de qué fuentes de datos han sido usadas para entrenar el modelo y las predicciones que el sistema ha generado. También se guardará en los logs cualquier modificación realizada al sistema. Todos estos registros podrán ser usados en posibles auditorías.

Para minimizar los posibles errores que pueda tener el sistema, sobre todo los relacionados con las malas predicciones y los falsos positivos, el proyecto contendrá un módulo de supervisión humana que permitirá a los trabajadores revisar periódicamente las predicciones que el modelo realiza y cambiarlas en caso de fallo. También, los usuarios dispondrán de una sección de reclamaciones para solicitar cambios si consideran que la predicción realizada por el sistema es errónea.

7.3.6 Pruebas y validación

Se realizarán auditorías internas periódicamente para detectar errores y sesgos que el modelo pueda tener y para prevenir posibles riesgos sociales que puedan ocurrir debido a una mala predicción.

Para evaluar el modelo y diagnosticar posibles errores, el sistema se someterá a pruebas en las que se usarán otras fuentes de fact-checking. El rendimiento y la eficiencia del sistema serán evaluados por diferentes métricas y los resultados serán comunicados a los usuarios para minimizar un posible riesgo de transparencia. Cualquier cambio realizado en el modelo o la corrección de errores también será transmitido a los mismos.

7.3.7 Conclusiones Éticas

El uso de IA para combatir la desinformación plantea importantes desafíos éticos, especialmente en cuanto a la privacidad, la transparencia y el tratamiento de datos sensibles. La aplicación de principios como la minimización de datos, la anonimización y la obtención del consentimiento explícito son esenciales para garantizar el cumplimiento legal y ético del sistema. Asimismo, la supervisión humana y las auditorías periódicas se presentan como mecanismos clave para mitigar riesgos y evitar la discriminación o el perfilado injustificado de los usuarios.

Capítulo 8

Conclusiones y trabajos futuros

En este capítulo se presentan las principales conclusiones extraídas del presente trabajo, en lo que respecta a los resultados experimentales obtenidos, así como desde una perspectiva personal del autor. Finalmente, se sugieren posibles líneas de trabajo futuras.

8.1 Conclusiones

8.1.1 Conclusiones relacionadas con el proyecto

- El objetivo principal del proyecto — desarrollar un sistema automático de verificación de desinformación mediante técnicas de *Deep Learning*, integrando un módulo de recuperación semántica (*Information Retrieval*) y un módulo de inferencia de lenguaje natural (NLI) — ha sido alcanzado satisfactoriamente. El sistema demuestra capacidad para combinar eficazmente recuperación de evidencias y razonamiento inferencial para verificar afirmaciones, contribuyendo a mitigar el impacto de la desinformación en contextos automatizados en el mundo real.
- En la primera fase experimental, se demostró que el ajuste fino mediante LoRA conserva, y en algunos experimentos, mejora el rendimiento de los modelos de la familia Llama frente a sus versiones base. Estas mejoras se observan en métricas clave como *accuracy*, *recall* y *F1-score*, sin incrementar significativamente el tiempo de entrenamiento. Por ejemplo, el modelo Llama-3.2-3B alcanzó un *F1-score* de 0.742 tras el ajuste fino, frente a 0.722 sin él.
- En la segunda fase, se evaluó el impacto de incorporar un módulo de recuperación semántica (SIR) basado en búsqueda vectorial. Los resultados muestran mejoras notables en todos los modelos ajustados con LoRA, siendo muy destacable el aumento de rendimiento en el modelo Llama-3.1-8B, donde el *F1-score* sube de 0.728 a 0.779, un incremento de +5.1 %. Este aumento puede deberse a que el módulo SIR recupera de forma sistemática dos evidencias por afirmación, lo cual enriquece el contexto de entrada para el módulo inferencial, especialmente en casos donde el dataset FEVER solo proporciona una evidencia válida.

- El análisis comparativo revela que la integración del módulo SIR potencia de forma efectiva la capacidad de inferencia de los modelos, sin necesidad de modificar su arquitectura base. Además, los beneficios del sistema son progresivamente mayores conforme se incrementa la escala del modelo, lo que sugiere que modelos de mayor capacidad aprovechan mejor la información adicional proporcionada por la recuperación semántica.
- En conjunto, los resultados obtenidos validan la propuesta del sistema híbrido SIR+NLI como una solución factible y eficaz para tareas automatizadas de verificación de hechos, sentando una base sólida para futuras investigaciones en esta línea.

8.2 Trabajos futuros

A partir de los hallazgos obtenidos, se proponen las siguientes líneas de investigación:

- **Explorar modelos generativos en lugar de clasificadores:** Sustituir el módulo de inferencia actual por modelos generativos como T5 o LLaMA 3 Instruct podría abrir la puerta a razonamientos explicativos más ricos y mayor capacidad de generalización. Estos modelos permiten formular veredictos a partir de evidencia textual de forma natural, lo cual resulta valioso en escenarios abiertos o con ambigüedad contextual, donde la simple clasificación puede resultar insuficiente.
- **Extender el módulo de recuperación semántica a nivel de frase:** Actualmente, el sistema recupera evidencia a nivel de documento mediante embeddings, lo que permite una primera aproximación semántica eficiente. Sin embargo, una mejora clave consiste en incorporar una segunda fase de recuperación más fina, centrada en la identificación de frases relevantes dentro de los documentos previamente seleccionados. Este enfoque híbrido permitiría optimizar el *FEVER Score*, al facilitar la detección de evidencias más precisas, sin necesidad de procesar bloques de texto extensos o irrelevantes.
- **Incluir una etapa de justificación de respuestas:** Como siguiente paso natural, se propone dotar al sistema de la capacidad para generar justificaciones o explicaciones en lenguaje natural. Esta funcionalidad mejoraría la transparencia del sistema y contribuiría a una mayor confianza por parte del usuario final, especialmente en dominios sensibles donde la explicabilidad de las decisiones es tan importante como su exactitud.

8.2.1 Conclusiones personales

La realización de este proyecto ha supuesto un proceso formativo de gran valor, tanto en el plano técnico como en el personal. A lo largo del desarrollo del TFM, he adquirido un conocimiento sólido y profundo en tareas relacionadas con el procesamiento del lenguaje natural.

Aunque el desarrollo del sistema no ha estado exento de dificultades, la experiencia global ha resultado enriquecedora. Afrontar el reto de diseñar un sistema experimental e innovador de verificación de desinformación ha fortalecido mis habilidades analíticas y mi capacidad para abordar problemas complejos.

Además, la manipulación de tecnologías punteras como LoRA y los sistemas de recuperación semántica ha despertado un interés por las técnicas de aprendizaje profundo aplicadas a problemas sociales relevantes, abriendo un camino que deseo seguir explorando en un futuro.

Bibliografía

- [1] Caceres, M.M.F., Sosa, J.P., Lawrence, J.A., Sestacovschi, C., Tidd-Johnson, A., Rasool, M.H.U., Gadamidi, V.K., Ozair, S., Pandav, K., Cuevas-Lou, C., et al., 2022. The impact of misinformation on the covid-19 pandemic. *AIMS public health* 9, 262.
- [2] Colomina, C., Margalef, H.S., Youngs, R., Jones, K., 2021. The impact of disinformation on democratic processes and human rights in the world. Brussels: European Parliament , 1–19.
- [3] Fallis, D., 2015. What is disinformation? *Library trends* 63, 401–426.
- [4] Gomaa, W.H., Fahmy, A.A., 2013. A survey of text similarity approaches. *International Journal of Computer Applications* 68.
- [5] Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, L., Chen, W., 2022. Lora: Low-rank adaptation of large language models, in: *International Conference on Learning Representations (ICLR)*, p. 3. URL: <https://arxiv.org/abs/2106.09685>.
- [6] Martín, A., Huertas-Tato, J., Huertas-García, Á., Villar-Rodríguez, G., Camacho, D., 2022. Facter-check: Semi-automated fact-checking through semantic similarity and natural language inference. *Knowledge-based Systems* 251, 109265. doi:[10.1016/j.knosys.2022.109265](https://doi.org/10.1016/j.knosys.2022.109265).
- [7] Mayoral, J., Parratt, S., Morata, M., 2019. Desinformacion, manipulacion y credibilidad periodísticas: una perspectiva historica. *Historia y comunicacion social* 24, 395–409.
- [8] Mikolov, T., Chen, K., Corrado, G., Dean, J., 2013. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781* .
- [9] Muennighoff, N., Tazi, N., Magne, L., Reimers, N., Schwenk, H., Gurevych, I., 2023. Mteb: Massive text embedding benchmark, in: *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics (EACL)*, Association for Computational Linguistics, Dubrovnik, Croatia. pp. 2014–2037. URL: <https://aclanthology.org/2023.eacl-main.148/>, doi:[10.18653/v1/2023.eacl-main.148](https://doi.org/10.18653/v1/2023.eacl-main.148).
- [10] Pavlyshenko, B.M., 2023. Analysis of disinformation and fake news detection using fine-tuned large language model. *arXiv preprint arXiv:2309.04704* URL: <https://arxiv.org/abs/2309.04704>.
- [11] Pérez-Rosas, V., Chocarro, D., Saquete, E., Martínez-Barco, P., 2021. Claimhunter: An unattended tool for automated claim detection on twitter, in: *Proceedings of the 1st*

- International Workshop on NLP and Social Dynamics (NLPSD 2021), pp. 23–31. URL: <https://ceur-ws.org/Vol-2877/paper3.pdf>.
- [12] Setty, V., 2024. Surprising efficacy of fine-tuned transformers for fact-checking over larger language models, in: Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval, ACM, Washington, DC, USA. pp. 2842–2846. doi:[10.1145/3626772.3661361](https://doi.org/10.1145/3626772.3661361).
- [13] Thorne, J., Vlachos, A., Christodoulopoulos, C., Mittal, A., 2021. Enhancing information retrieval in fact extraction and verification, in: Proceedings of the AAAI Conference on Artificial Intelligence, pp. 10669–10677. URL: <https://ojs.aaai.org/index.php/AAAI/article/view/17220>.
- [14] Thorne, J., Vlachos, A., Cocarascu, O., Christodoulopoulos, C., Mittal, A., 2018. The fact extraction and verification (fever) shared task. arXiv preprint arXiv:1811.10971 .
- [15] Truică, C.O., Apostol, E.S., 2023. It’s all in the embedding! fake news detection using document embeddings. Mathematics 11, 508. doi:[10.3390/math11030508](https://doi.org/10.3390/math11030508).
- [16] Vaibhav, V., Mandyam, R., Hovy, E., 2019. Do sentence interactions matter? leveraging sentence level representations for fake news classification, in: Proceedings of the Thirteenth Workshop on Graph-Based Methods for Natural Language Processing (TextGraphs-13), Association for Computational Linguistics, Hong Kong. pp. 134–139. URL: <https://aclanthology.org/D19-5316/>, doi:[10.18653/v1/D19-5316](https://doi.org/10.18653/v1/D19-5316).
- [17] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I., 2017. Attention is all you need, in: Advances in Neural Information Processing Systems, Curran Associates, Inc.
- [18] Vosoughi, S., Roy, D., Aral, S., 2018. The spread of true and false news online. Science 359, 1146–1151.
- [19] World Economic Forum, 2024. The global risk report 2024. <https://www.weforum.org/reports/global-risks-report-2024>. Accessed: 2025-03-01.